

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 声纹识别算法在光纤分布式声波
传感系统信号识别中的应用研究

专业学位类别	电子信息
学 号	202222011430
作者姓名	李晓楠
指导教师	吴宇 教 授
学 院	信息与通信工程学院

分类号 TN912.34 密级 公开
UDC ^{注1} 621.39

学 位 论 文

声纹识别算法在光纤分布式声波传感系统信号识别中的应用研究

(题名和副题名)

李晓楠

(作者姓名)

指导教师

吴宇

教 授

电子科技大学

成 都

(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息

专业学位领域 通信工程(含宽带网络、移动通信等)

提交论文日期 2025 年 4 月 14 日 论文答辩日期 2025 年 5 月 29 日

学位授予单位和日期 电子科技大学 2025 年 6 月

答辩委员会主席 冉曾令

评阅人 冉曾令、王子南

注 1: 注明《国际十进分类法 UDC》的类号。

Research on the Application of Voiceprint Recognition Algorithm in Signal Recognition of Fiber Optic Distributed Acoustic Sensing Systems

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline **Electronic Information**

Student ID **202222011430**

Author **Li Xiaonan**

Supervisor **Prof. Wu Yu**

School **School of Information and Communication**

Engineering

摘要

随着工业物联网和智能化技术的发展,分布式光纤声波传感系统(Distributed fiber Acoustic Sensing, DAS)的应用从传统的地质灾害预警和设备状态检测,逐步深入到更复杂的安全监控和工业环境监测。在管道事件监测的场景下的多通道数据识别中,基于CPU方案的多维特征提取方法存在实时性弱以及功耗高的问题,无法满足系统对高效的数据处理能力和快速响应能力的需求。声纹识别技术是通过分析个体的语音特征来辨识说话人身份的技术,声纹特征具有易于提取、算法复杂度低的优点,基于此优势本文尝试将声纹识别算法应用于分布式光纤传感系统的管道事件监测识别中。

本文的研究目标是针对人工挖掘、油夯机施工、挖机挖掘三类典型管道入侵事件实现多通道实时声纹识别,设计了分布式光纤传感系统的基于FPGA片上采集-MFCC提取、上位机识别方案,搭建了FPGA+CPU混合构建的分布式光纤声纹识别系统,实现了多通道DAS信号的并行化处理、实时识别。在实验和实际性能验证中,该系统在保证较高识别率的同时,加速了特征提取处理并降低了识别算法的复杂度,在多通道数据的识别中表现出更快的识别速度。本文的具体研究内容包括:

(1)研究了声纹识别算法,基于DAS信号特征将关键参数作适应性调整:通过分析人工挖掘、油夯机施工及挖机挖掘信号的时频特征,采用了MFCC作为语音特征参数,从实时识别性能方面分析确定了GMM-UBM识别模型,并结合多阈值判决机制提升分类性能。实验研究了梅尔滤波器数量、一阶和二阶动态参数、高斯模型数量参数对识别性能的影响,调整参数后的结果表明,模型在验证集上实现对于三类事件平均识别率达97.51%,对500通道各3s数据识别耗时8.31ms。

(2)设计了分布式光纤传感系统的片上采集-解调-特征提取、上位机识别方案:研究了基于FPGA的多通道梅尔倒谱系数提取算法,实现了一种多通道数据跨步寻址存储方法、双缓存结构的分帧方法和一种16点DCT的七级流水结构,最后根据的识别、判决原理,确定了使用上位机实现识别算法。

(3)对系统的性能进行测试和分析:通过实验和实际系统测试,实验结果显示特征提取部分对500通道各3s数据的提取时间为399.35ms;优化后的DCT计算结构比直接计算的FF和LUT资源使用情况减少了2.24%和5.81%;在实际测试中,对500个传感通道的3s声音信号进行实时识别的平均识别准确率为91.31%,总识别时间约为0.5s,最长监测距离可达81.89km。

关键词: 声纹识别, 光纤分布式声波传感, FPGA, 入侵事件监测

ABSTRACT

With the advancement of Industrial Internet of Things (IIoT) and intelligent technologies, distributed fiber acoustic sensing (DAS) systems expand their applications from traditional geological disaster early warning and equipment condition monitoring to more complex safety supervision and industrial environment monitoring. In pipeline event monitoring scenarios requiring multi-channel data identification, CPU-based multidimensional feature extraction methods exhibit limitations in real-time performance and power efficiency, failing to meet system demands for high-speed data processing and rapid response capabilities. Voiceprint recognition technology identifies speakers by analyzing individual vocal characteristics, offering advantages in simplified feature extraction and low algorithmic complexity. Leveraging these strengths, thesis proposes the application of voiceprint recognition algorithms to pipeline event monitoring in distributed fiber sensing systems.

The research objective of thesis is to achieve multi-channel real-time acoustic recognition for three typical pipeline intrusion events: manual excavation, oil rammer construction, and excavator excavation. A distributed optical fiber sensing system is designed based on FPGA on-chip acquisition and MFCC features extracting, combined with a host computer recognition scheme, and an FPGA+CPU hybrid-architecture distributed fiber-optic acoustic recognition system is constructed, achieved parallel processing and real-time recognition capabilities for multi-channel DAS signals. In experimental and practical performance verification, this system not only maintains high recognition accuracy but also accelerates feature extraction processing and reduces the complexity of recognition algorithms, demonstrating faster recognition speeds in multi-channel data recognition. The specific research contents of thesis include:

(1) Adaptive voiceprint recognition algorithms based on DAS signal characteristics: By analyzing time-frequency features of manual excavation, oil rammer operation, and excavator signals, Mel-frequency cepstral coefficients (MFCC) serve as acoustic features, while the Gaussian Mixture Model-Universal Background Model (GMM-UBM) framework is selected for real-time performance optimization. A multi-threshold decision mechanism improves classification accuracy. Experimental results show 97.51% average

recognition accuracy on validation sets, with 8.31 ms processing time for 500-channel 3s data.

(2) On-Chip System Design: The research develops FPGA-based multi-channel MFCC extraction algorithms to address the computational bottlenecks of traditional CPU-based approaches. Key innovations include a cross-stride addressing method for efficient multi-channel data storage, a dual-buffer structure for seamless frame segmentation, and a 7-stage pipelined 16-point DCT architecture to accelerate feature computation. These hardware optimizations minimize latency and resource utilization while maintaining compatibility with the host computer's recognition algorithms. The final design integrates on-chip signal processing with a software-based recognition framework, enabling real-time decision-making and visualization of pipeline event monitoring results.

(3) System Performance Evaluation: Through experiments and practical system testing, the results demonstrate that the feature extraction module takes 399.35 ms to process 3-second data from 500 channels. The optimized DCT computing architecture reduces FF and LUT resource utilization by 2.24% and 5.81% respectively compared to direct computation. In practical testing, the system achieves an average recognition accuracy of 91.31% for real-time identification of 3-second audio signals from 500 sensing channels, with total recognition time of approximately 0.5 seconds and a maximum monitoring distance reaching 81.89 km.

Keywords: Voiceprint Recognition, Distributed Fiber Acoustic Sensing, FPGA, Intrusion Event Detection

目 录

第一章 绪论.....	1
1.1 背景及研究意义.....	1
1.2 国内外研究现状.....	3
1.2.1 声纹识别技术国内外研究现状.....	3
1.2.2 FPGA 信号识别国内外研究现状.....	6
1.3 本文研究内容及各章安排.....	7
第二章 管道入侵事件监测系统.....	9
2.1 系统结构.....	9
2.2 基于 Φ -OTDR 技术的探测原理.....	9
2.2.1 瑞利散射原理.....	9
2.2.2 Φ -OTDR 技术.....	10
2.2.3 系统探测原理.....	11
2.3 信号采集方法.....	12
2.4 探测光脉冲触发-采集控制方法.....	13
2.5 相位解调原理.....	14
2.6 系统性能.....	16
2.7 本章小结.....	16
第三章 DAS 信号的声纹识别算法研究.....	17
3.1 声纹识别的基本流程.....	17
3.2 特征提取方法及对比分析.....	18
3.2.1 线性预测系数.....	18
3.2.2 线性预测倒谱系数.....	19
3.2.3 梅尔倒谱系数.....	20
3.2.4 动态差分系数.....	23
3.2.5 特征提取方法对比分析.....	24
3.3 识别模型对比分析.....	26
3.4 基于多分类判决的 GMM-UBM 声纹识别模型.....	27
3.4.1 高斯混合概率密度函数.....	28
3.4.2 EM 算法.....	28
3.4.3 K-means 迭代初始化.....	29
3.4.4 MAP 自适应算法.....	31
3.4.5 单阈值对数似然比判决.....	32
3.4.6 多阈值分类判决.....	32
3.5 实验和结果分析.....	33

3.5.1 数据集构建.....	33
3.5.2 识别效果评价.....	34
3.5.3 对梅尔滤波器数量的分析.....	35
3.5.4 对动态参数的分析.....	36
3.5.5 对高斯模型数量的分析.....	36
3.5.6 模型识别效果和对单阈值识别的分析	37
3.6 本章小结.....	39
第四章 管道入侵事件声纹识别系统设计与算法实现	41
4.1 系统结构.....	41
4.2 同步时钟驱动及探测参数设置	42
4.3 特征提取部分设计.....	42
4.3.1 预处理模块.....	42
4.3.2 梅尔倒谱系数计算模块.....	45
4.4 数据传输部分设计.....	53
4.4.1 数据上传设计.....	54
4.4.2 控制下发设计.....	55
4.5 逻辑资源占用情况.....	55
4.6 上位机识别显示设计.....	55
4.6.1 TCP/IP 接收发送模块.....	56
4.6.2 声纹识别模块.....	56
4.6.3 显示控制模块.....	57
4.7 本章小结.....	57
第五章 基于 DAS 的声纹特征提取实验和性能验证	59
5.1 特征提取实验与性能分析	59
5.1.1 预处理模块测试验证.....	59
5.1.2 特征提取部分处理周期性和计算性能评估	61
5.1.3 资源占用对比.....	62
5.2 系统搭建.....	63
5.3 测试性能.....	64
5.4 现场测试.....	65
5.5 本章小结.....	67
第六章 总结与展望	69
参考文献.....	71

图目录

图 1-1 特征领域和模型领域发展过程	3
图 2-1 管道入侵事件的监测系统结构	9
图 2-2 入射光与散射光谱	10
图 2-3 外差探测结构	12
图 2-4 AD9643 时序	12
图 2-5 差分-单端转换结构	13
图 2-6 脉冲触发-采集控制结构	14
图 3-1 声纹识别的训练和识别流程	17
图 3-2 声音产生模型	18
图 3-3 Mel-Hz 映射关系	21
图 3-4 梅尔倒谱系数提取流程	21
图 3-5 梅尔滤波器	22
图 3-6 油夯机施工作业声音信号 12 维梅尔倒谱系数	23
图 3-7 管道信号时域、频域图	24
图 3-8 信号频谱能量分布	25
图 3-9 三类信号的前 12 维梅尔滤波能量分布	26
图 3-10 GMM-UBM 训练及识别流程	27
图 3-11 EM 算法更新参数流程	28
图 3-12 K-means 算法迭代流程	30
图 3-13 目标事件建模自适应过程	31
图 3-14 判决示意图	33
图 3-15 各类型事件等错误率、滤波器数关系曲线	35
图 3-16 GMM-UBM 模型高斯模型数-等错误率关系图	37
图 3-17 ROC 曲线	38
图 3-18 GMM-UBM 模型识别混淆矩阵	38
图 4-1 声纹识别系统算法结构	41
图 4-2 跨步寻址电路及读写示意图	43
图 4-3 状态机分帧逻辑示意图	44
图 4-4 预处理实现结构	45
图 4-5 梅尔滤波器系数分布	46

图 4-6 梅尔滤波计算结构	46
图 4-7 梅尔滤波实现结构	47
图 4-8 输入加法器单元结构	49
图 4-9 三级加法数计算结构	50
图 4-10 8 点 DCT 变换结构	51
图 4-11 4 点 DCT 变换结构	52
图 4-12 16 点 DCT 蝶形算法计算结构	52
图 4-13 DCT 七级流水计算结构	53
图 4-14 AXI-DMA IP 配置	54
图 4-15 AXI-GPIO 配置	55
图 4-16 逻辑资源占用情况	55
图 4-17 上位机显示界面	57
图 5-1 通道信号分帧第一帧理论波形及仿真结果	60
图 5-2 各通道分帧信号第二帧理论波形及仿真结果	60
图 5-3 梅尔倒谱系数仿真计算耗时	61
图 5-4 特征提取部分资源占用情况	63
图 5-5 DAS 光学集成模块照片	63
图 5-6 采集-处理板卡结构	64
图 5-7 输气管道入侵事件的声纹识别系统示意图	64
图 5-8 输气管道现场测试图	65
图 5-9 系统实时响应界面	66

表目录

表 2-1 系统性能评价指标	16
表 3-1 管道入侵事件时域样本集的样本数据构成	33
表 3-2 预测关系类别	34
表 3-3 MFCC 及加入动态参数的等错误率	36
表 3-4 三类事件寻优阈值	39
表 3-5 识别参数指标	39
表 4-1 HEVC 标准整数矩阵系数	48
表 4-2 16 点 DCT 中间乘法器单元的移位-加法分解	49
表 4-3 8 点 DCT 中间乘法器单元的移位-加法分解	51
表 4-4 4 点 DCT 中间乘法器单元的移位-加法分解	51
表 5-1 识别报警结果	66
表 5-2 识别系统性能指标	67

第一章 绪论

1.1 背景及研究意义

随着工业物联网和智能化技术的迅猛发展,工业监测网络规模不断扩大,监测需求日益多样化,这一趋势不仅推动了数据采集和处理技术的进步,还促进了智能化监测系统在各类工业场景中的广泛应用。分布式光纤声波传感系统以其具备分布式感知、长距离覆盖、高灵敏度等特点,在管道入侵事件监测中具有独特的技术优势。然而,在庞大的监测网络、多样的事件类型带来的海量数据下,现有识别技术无法及时响应异常事件来源和类型,当发生非法入侵时会直接带来安全隐患,不仅导致资源损失,还可能引发爆炸、火灾等致命灾难,对周边区域造成严重环境危害。如何使系统兼具高效的数据识别能力与快速响应能力,已成为亟待解决的关键技术难题。

DAS 系统^[1]是一种利用光纤作为传感元件和信号传输介质来获取动态应变信息的传感系统,被广泛应用于周界安全、资源勘探、油气管道检测、通信线路检测、高铁、船舶、机场监控等许多国防和工业领域^[2-4]。其利用光纤作为传感元件和信号传输介质,结合相位敏感光时域反射(Phase-sensitive Optical Time Domain Reflect, Φ -OTDR)技术,通过布设长距离的传感光纤,沿光纤路径连续探测光缆上的振动或声音等动态变化信息,精确定位扰动位置,并对信号进行有效识别,实现动态应变的远程、分布式、多点实时定量检测。

系统常用的识别技术包括多维特征参数融合技术和深度学习。多维特征参数融合技术通常使用短时傅里叶变换^[5]、时频分析^[6]或小波变换^[7]等方法提取信号的频率特性、时域波形特性及能量分布等特征参数,并将其用于模式匹配和分类算法中,实现事件类型的判别和状态监测。多维特征参数融合在实验室环境和小规模应用中取得了一定效果,但其实际应用仍存在诸多限制:特征参数提取过程中通常依赖复杂的信号处理算法,涉及大量矩阵运算与频域分析,其计算复杂度随监测通道数量、采样频率和带宽的增加呈指数级增长^[8]。此外,特征的多维特性会导致数据融合过程的复杂化,常需引入加权模型或多阶段优化算法,从而进一步增加算法的计算负担。不仅如此,高复杂度算法不仅对硬件算力要求更高,还会延长数据处理的时间,难以满足工业场景对实时监测的严格需求。深度学习方法在系统的模式识别中同样存在局限性,其模型的推理过程通常涉及大规模矩阵运算和非线性激活函数计算,计算开销随网络深度与输入数据维度的增加而急剧上升。这种高开销直接导致推理时间延长,降低了数据的处理效率。由于系统需要对传感网络覆盖

范围内的通道数据进行并行分析，单个通道的延迟都会引发监测链路的整体瓶颈，导致异常事件未能被及时识别。

声纹识别技术作为一种基于语音特征分析的身份辨识技术，凭借其特征提取便捷、算法复杂度低及实时性强的特点，已在智能助手、移动金融和安全刑侦等领域得到广泛应用。近年来，国内外学者已尝试将该技术拓展至工业场景的模式识别领域^[9]。

基于上述问题，本文结合声纹识别技术的算法优势，探索其在 DAS 系统事件监测中的应用，通过解析声学信号特征实现工业场景特定事件的高效识别。相较于深度学习与多维特征参数融合算法，一些声纹识别技术在单通道场景中具有耗时短、复杂度低的优势，然而受限于 x86-64、PowerPC 等传统处理器的运算能力，在数十公里的传感距离下，DAS 系统面临多通道海量数据的识别挑战，仍然难以实现长距离信号的实时识别，系统在处理海量数据的特征参数时存在同样的延迟问题，导致异常事件或入侵信号的响应时效性不足，限制了 DAS 系统广域覆盖、灵敏度高的探测优势的充分发挥。

针对实时性瓶颈，研究与实践领域逐渐转向加速处理器的解决方案。当前主要加速器件包括数字信号处理器（Digital Signal Processor, DSP）、专用集成电路（Application-Specific Integrated Circuit, ASIC）、现场可编程门阵列（Field-Programmable Gate Array, FPGA）以及图形处理器（Graphics Processing Unit, GPU）。然而，这些器件在 DAS 系统应用中均存在特定的性能约束与适用性差异。

ASIC 能够通过芯片级定制实现极高的性能和能效比，但其开发成本高、周期长，且缺乏灵活性，难以适应尚未大规模推广的应用场景，因此不适合需要快速迭代优化的 DAS 系统。DSP 作为专用的信号处理芯片，集成了高效信号处理能力与多算法优化支持，在雷达信号处理等领域获得广泛应用，然而，DSP 在处理 DAS 数据时往往需要借助 FPGA 进行数据采集，当数据从 FPGA 传输到 DSP 时，受限于接口带宽，导致系统的开发成本增加。GPU 具备强大的并行计算能力和高性能计算特性，已有部分研究者将其用于 DAS 数据处理，能够显著提升数据分析速度，然而，GPU 的高功耗和较大的数据传输延迟使其在对体积和能效要求较高的设备中难以应用。

相比之下，FPGA 在 DAS 数据处理中优势更加突出。FPGA 片上集成了大量的可编程逻辑单元，如查找表、触发器、块存储器等，还有 DSP 单元以及高速通信接口等丰富资源，支持在单芯片内实现数据采集、特征识别与数据传输的全流程功能，还允许通过动态重构灵活调整硬件配置以适应不同应用需求。这种高度集成

和可重构性显著简化了系统设计，降低了开发复杂性，同时提高了系统的整体性能和能效，因此使用 FPGA 加速可以解决 DAS 系统的数据处理、识别与传输问题。

综上，本文的设计基于低功耗、高时效的系统设计理念，充分利用 FPGA 的并行化计算优势，结合声纹识别技术特点，为 DAS 系统工业场景下的多通道事件监测遇到的技术难题提供可行的 FPGA+CPU 解决方案。

1.2 国内外研究现状

1.2.1 声纹识别技术国内外研究现状

在 21 世纪前，声纹识别技术主要用于验证说话人。“声纹”这一概念最早在 1945 年由 Bell 实验室 Kersta 等人^[10]提出，他们通过肉眼观察语谱图进行匹配，首次定义了声纹。随着计算机技术的进步，声纹识别逐渐从人工匹配转变为机器识别，图 1-1 展示了声纹识别技术的特征领域典型方法和模型领域发展过程。




图 1-1 特征领域和模型领域发展过程

在 20 世纪 60 年代到 70 年代，声纹识别主要的研究重点在声纹识别的特征提取上。1969 年，Rabiner 等人首次提出了基于倒谱^[11]的声纹识别算法，倒谱分析通过对信号进行傅里叶变换、对数变换后再做逆傅里叶变换，能够有效地分离信号中的语音特征和噪声。

在 20 世纪 70 年代至 80 年代，研究的重点仍是特征提取方法，更深入地研究了各种声学参数的线性或非线性处理，同时也有模版匹配的方法应用到声纹识别。1976 年，Atal 提出线性预测倒谱系数^[12]（Linear Predictive Cepstrum Coefficients, LPCC），假设当前语音采样点可以用其前若干个采样点的线性组合来预测，通过对语音信号进行线性预测分析，提取倒谱特征描述语音信号的声学特性。LPCC 使当时的声纹识别技术在鲁棒性和准确率上有了显著提升。1978 年，Sakoe 和 Chiba 提出动态时间规整^[13]（Dynamic Time-warping, DTW）方法，通过计算两个语音序列的每个点对的欧几里得距离，得到累积距离矩阵，寻找最小总距离的路径，也称为

“时间对齐路径”，找出它们在时间维度上的最佳匹配。1980年，Davis 和 Mermelstein 提出梅尔倒谱系数^[14]（Mel Frequency Cepstral Coefficients, MFCC），现已成为语音信号识别领域应用最广泛的特征参数之一。该系数基于人耳听觉系统的非线性感知特性，通过梅尔刻度（Mel Frequency Scale）将语音信号的线性频率域映射至符合听觉敏感度分布的非线性频域空间。Mel 标度的频率域更能体现出人耳听觉特性的非线性，使 MFCC 能够有效捕捉语音信号的特征。1985年，Doddington 提出了语音共振峰特征匹配^[15]的方法，它是一种由声道的谐振特性决定的频率峰值，其位置和强度主要受发声器官的物理结构影响，使共振峰特征的个体差异性显著，成为说话人身份的独特标志，共振峰的提出也为声纹识别特征提取提供了新的方向，现代声纹识别技术如深度学习声纹模型和隐马尔可夫模型（Hidden Markov Model, HMM）常利用共振峰来提取声谱信息。

在 20 世纪 90 年到 21 世纪初，更多识别模型相继应用到声纹识别中。1995 年 Reynolds 提出高斯混合模型^[16]（Gaussian Mixture Model, GMM），模型假设数据分布是多个高斯分布的线性组合，每个高斯模型都估计出不同的均值、方差、权重等参数。这种方法简单灵活、鲁棒性较高，成为说话人识别领域的主流算法，使非特定文本的说话人识别效果取得了一定进步。1996 年，隐马尔可夫模型开始应用于声纹识别中^[17]，根据马尔可夫假设建模不同语音单元，如音素之间的过渡概率，学习语音的时间序列模式来区分不同的说话人，适用于特定文本的说话人识别。2006 年，由 Campbell 等人提出支持向量机^[18]（Support Vector Machine, SVM），这是一种用于分类和回归的机器学习算法，通过构建一个最优超平面，将不同类别的数据点分开，同时最大化类别之间的间隔。2000 年，Reynolds 等人进一步提出了高斯混合模型—通用背景模型（Gaussian mixture model-universal Background Model, GMM-UBM），为声纹识别技术从实验室走向实用作出了重要贡献。2007 年，Dehak 等人提出 i-vector 模型^[19]，假设声学特征服从高斯混合模型，提取每条语音的 GMM 超向量，将高维声学特征表示为低维固定长度的向量，计算相似度进行匹配。这一阶段的声纹模型大多基于参数分析方法，针对声学信号特性与声纹识别任务需求，需先验定义声学特征中各信息因子变量的概率关系，并通过统计推断方法估计声纹特征参数。为降低模型训练与推断的计算复杂度，此类统计模型通常假定特征空间线性可分且数据服从高斯分布，因此被归类为线性高斯混合模型。

21 世纪后，深度学习在语音信号处理领域快速发展，开始应用到声纹识别中，同时也有研究提出特征提取的改进方法。2010 年，Hossan 等人提出了改进的 MFCC^[20]特征提取方法，这种方法在 MFCC 基础上使用分布式 DCT，通过将梅尔滤波器组的输出划分为多个子段，分别对每段应用 DCT 变换，以更贴合滤波器输

出信号的非均匀相关性结构优化特征去相关效果，将 MFCC 及其一阶差分、二阶差分特征共同作为特征参数，识别模型使用 GMM，在说话人识别中将识别率提升了 6.36%。2014 年 Variani 等人研究了深度神经网络^[21]（Deep Neural Networks，DNN）在小规模文本相关声纹验证中的应用，提出了基于 DNN 的高效声纹验证方法，系统对加性噪声具有更强的鲁棒性，等错误率在安静条件下比 i-vector 系统提高了 14%，在噪声条件下提高了 25%。2017 年 Li 等人提出了一个基于神经网络的端到端^[22]（End-to-end）嵌入式声纹识别系统，把声纹特征映射到一个超球面上，使用 ResCNN 和 GRU 来提取声学特征，通过均值池化（mean pooling）生成话语级别的说话人嵌入，并基于余弦相似度通过三元组损失函数（triplet loss）进行训练。这种端到端的深度学习将特征提取和判决整合在一起，直接学习输入与输出之间的映射关系，其识别率对比 DNN-based i-vector baseline 方法，相对提高 60%且具有很好的跨语言能力。2018 年，Snyder 等人提出在深度神经网络中，将可变长度的话语映射到固定维度的 x-vector^[23]用于说话人识别，同时在训练数据中添加噪声和混响，提高模型鲁棒性。

由于声信号也蕴含着丰富的与设备结构、运行状态等密切相关的信息，近年来，声纹识别技术正突破传统身份认证领域，向工业设备健康监测领域深度发展。国内有学者将声纹识别技术应用于设备的状态识别。

2016 年，陈佳音提出一种基于光纤 MOEMS 声传感器技术，利用直升机声纹特性构建远距离捕捉、监控直升目标的声纹识别系统^[24]，根据直升机声纹低频特征明显、谐波性好的特点，结合“双谱”（BISPECTRUM）屏蔽高斯噪声和选取谐波峰的能力、梅尔倒谱系数对低频段的良好分析能力，提出双谱、梅尔倒谱联合特征提取算法，建模使用支持向量机（Support Vector Machine，SVM），系统能对直升机类型有效分类，达到较高的识别率。2017 年，王丰华等人提出了一种通过噪声特征识别变压器状态的方法^[25]，基于改进梅尔频率倒谱系数和矢量量化算法（Vector Quantization，VQ）的声纹识别模型，将 MFCC 特征向量结合加权处理法和主成分分析法，使用 VQ 算法快速识别，可以准确反映不同铁芯压紧程度下的变压器噪声特征。2024 年，杨佳沛等人提出基于 DTW-GMM 的光纤传感系统声纹识别方法^[26]，通过三电平削波法提取基音周期特征，并结合动态时间规整算法筛选说话人样本，同时提取梅尔频率倒谱系数特征，采用高斯混合模型-期望最大化算法进行声纹识别。系统可准确检测 400 段时长 3~5 秒的文本无关语音片段，综合识别准确率达 94.75%，为易燃易爆环境中的设备故障监测、应急救援及渗漏检测等领域提供了声纹识别方案。

声纹识别技术历经模板匹配、概率模型到深度学习的跨越式发展,在说话人认证领域已构建成熟体系,通过基频、共振峰等声学特征提取与深度神经网络建模实现了高精度识别。然而,针对非语音信号,如动物鸣叫、机械异响、事件分类等的研究尚处初级阶段,在 DAS 系统的管道入侵监测中,声纹识别在监测识别的实时性方面具有广阔的研究价值与应用潜力。

1.2.2 FPGA 信号识别国内外研究现状

光纤传感领域的信号类型识别系统结构一般为 FPGA 或 FPGA+DSP 双核处理架构,信号采集和处理在 FPGA 端,FPGA 或 DSP 识别已处理的传输数据。2017 年,沈隆翔设计了基于相位式光时域反射计的分布式光纤识别预警系统^[27],信号识别部分使用 DSP+FPGA 架构,在 FPGA 端利用数字 IQ 解调算法获取信号幅度信息;在 DSP 端,通过差分运算实现振动源定位,并结合图像处理、形态学特征提取以及 BP 神经网络进行振动类型的识别,该方法显著提高了识别准确性,同时减少了响应耗时。2018 年,盛智勇等人使用 FPGA 采集传来的原始数据,通过链路口送到 DSP 中,两片 DSP 对信号进行并行地检测识别,将信号分段并计算频谱能量的比值,层层比较阈值判断信号类型^[28],识别平均耗时为 0.659s。2019 年,翁凌锋使用 FPGA 设计了基于 Michelson 分布式振动光纤传感系统^[29],实现了以过零率作为特征向量,SVM 作分类模型的入侵事件识别。实验对五种事件各自识别率在 90%以上,识别时间 0.046s。2020 年,闫建行等人针对长距离油气管道预警信号所产生的庞大数据量及精准识别的问题,提出了 FPGA 和 DSP 为核心硬件平台的分布式光纤预警系统^[30],对 21 km 处的机械挖掘、打孔盗油和人工挖掘中都验证了系统的较高的识别准确性。同年,杨家隆实现了一种基于 FPGA 的非本征法布里-珀罗干涉(Extrinsic Fabry-Perot Interferometer, EFPI)光纤传感器白光干涉解调系统^[31],以 FPGA 为核心,通过优化 FFT 算法、Buneman 频率估计及相位解调算法,系统在 FPGA 硬件上完成高精度腔长解调,单次处理时间仅 875ms,解调精度达 1nm。2023 年,赵攀峰、王一群实现了一种基于 FPGA 与 CNN 的工业零件识别系统^[32],通过 FPGA 硬件平台实时采集零件图像,利用双边滤波、灰度化与二值化进行预处理,并提取 Hu 不变矩作为形状特征输入轻量化 CNN 模型进行分类。实验表明,该系统在 4 类零件识别中达到 98.24%的平均准确率,单次识别耗时 875ms。

综上所述,在 DAS 系统的实时信号处理中,传统的算法加速方案多依赖于专用数字信号处理器实现。虽然 DSP 通过优化指令集和硬件加速单元能够快速部署复杂的软件算法,但其底层仍受限于串行指令执行模式。这种基于软件流水线的处

理方式在应对 DAS 系统高频采样数据流时，容易因指令竞争和资源调度产生处理瓶颈，导致实时吞吐量下降，特别是在多通道协同监测场景下，多个 DSP 器件的级联运行不仅增加系统复杂度，其静态功耗叠加效应也与当前计算趋势相悖。相比之下，FPGA 凭借其分布式硬件逻辑单元阵列，能够构建与算法特征深度匹配的数据流架构，通过并行的硬件加速架构突破传统处理器的串行计算模式。其动态重构能力支持算法级硬件优化，在保持灵活性的同时实现纳秒级低延迟处理，且单芯片集成方案可显著降低系统功耗。采用 FPGA 实现的 DAS 信号实时处理系统为智能监测系统的能效优化提供了解决方案。

1.3 本文研究内容及各章安排

本文研究了声纹识别算法在管道入侵事件识别中的应用，设计了基于 FPGA 的多通道事件的声纹识别架构，构建数据采集-信号处理与传输一体化的分布式光纤声波传感管道入侵事件识别系统，验证该算法在降低计算复杂度与提升实时性方面的可行性。本文各章节安排如下：

第一章为绪论。基于工业物联网背景下管道安全监测需求，阐述 DAS 系统面临的实时性瓶颈，指出现有多维特征参数融合算法与深度学习方法因计算复杂度高导致的局限性，论证结合声纹识别与 FPGA 加速技术的必要性。系统回顾声纹识别技术从倒谱分析、梅尔频率倒谱系数到深度学习模型的发展历程，探讨其在工业监测中的潜在应用。通过对比分析光纤传感领域中 FPGA 与 DSP 架构的性能差异，指出现有方案在并行处理与能效上的不足，说明本文研究声纹识别技术和使用 FPGA 实现算法加速的必要性。

第二章介绍管道入侵事件监测系统。首先描述系统整体架构，包括光学集成模块与 FPGA 和 ARM 协同工作结构，随后详细分析基于 Φ -OTDR 技术的探测原理和脉冲触发-采集控制方法。结合 AD9643 芯片时序与差分-单端转换结构，详述信号采集流程，阐明相位解调技术原理，最后给出入侵事件监测系统的性能指标。

第三章为声纹识别算法研究。阐述了声纹识别的基本流程，包括特征提取、模型训练与实时匹配两个阶段，为后续声纹识别算法研究和硬件加速算法设计奠定理论基础。围绕管道入侵事件声纹识别系统的特征提取与模型优化展开，对比分析了线性预测系数、线性预测倒谱系数及梅尔频率倒谱系数三类方法的适用性。在此基础上，针对系统的监测需求，分析了现有各类识别模型的优缺点和高斯混合模型-通用背景模型对于需求的适用性，详细阐述其训练流程及多阈值分类判决机制。通过实验分析梅尔滤波器数量和高斯模型数量对识别性能的影响，验证多阈值判决相较于单阈值的优势，最终根据性能指标评估了系统的性能。

第四章提出了基于 FPGA+CPU 的入侵事件多通道声纹识别方法，特征提取模块采用双 FIFO 分帧结构与状态机控制，结合乒乓缓冲机制实现数据累积与重叠分帧；利用蝶形算法优化 16 点离散余弦变换，设计七级流水线提升梅尔倒谱系数计算效率。数据传输部分基于 AXI4-Stream 协议实现 FPGA 至 ARM 的高速流式传输。上位机采用 Labview 构建时空可视化界面，调用 GMM-UBM 模型进行多分类判决，实现事件识别与报警。

第五章对 FPGA 的声纹特征提取算法性能进行验证并搭建系统现场测试，通过仿真实验验证预处理模块计算准确性与特征提取实时性，搭建由 DAS 光学集成模块、主控板卡及上位机组成的硬件平台，在输气管道现场模拟人工挖掘、挖机挖掘、油夯机施工三类事件，测试系统的平均响应时间。

第六章为总结与展望。总结本文的主要工作内容和创新点，并指出工作内容的不足之处和有待优化的方向，提出后续研究工作的展望。

第二章 管道入侵事件监测系统

声纹识别信号基于分布式光纤管道入侵监测系统进行采集，其获取流程包含探测、采集与解调三个阶段。本章将阐述基于 Φ -OTDR 的探测技术基本原理，分析信号的采集方法和系统的解调原理，同时给出监测系统的主要性能指标。

2.1 系统结构

分布式光纤管道入侵事件监测系统结构如图 2-1，该系统主要由三个部分构成：

(1) 基于 Φ -OTDR 技术的光学集成模块发出并探测沿纤光信号，完成光信号到电信号的转换过程，电信号经过 ADC 芯片进行数字化处理，转换为可供后续处理的数字信号；

(2) FPGA 端负责控制光模块脉冲宽度和频率、接收 ADC 发出的数字信号，同时解调相位信息还原振动信号，其内置的多通道数字解调算法可实时提取光纤沿线每米空间分辨率的相位扰动信息，经 ARM 端将信号传输至上位机；

(3) 上位机接收振动信号并在软件界面显示，同时向 FPGA 发送触发指令控制探测、采集。




图 2-1 管道入侵事件的监测系统结构

FPGA 与 ARM 采用可编程逻辑-处理系统（Programmable Logic-Processing System, PL-PS）架构协同运算。FPGA 端执行信号实时处理任务，处理系统端 ARM 核作为核心控制器，负责数据封装、通信协议解析及与上位机的实时交互。

以上为系统的整体结构，系统设计原理将从光学集成模块开始阐述。

2.2 基于 Φ -OTDR 技术的探测原理

2.2.1 瑞利散射原理

在光纤传感技术中，光纤不仅是信息传输的媒介，同时也作为整个传感系统的感知元件起到关键作用。当外部扰动作用在光纤上时，光纤会发生应变，导致折射

率的变化,从而引起光信号在强度、相位、频率和偏振等方面的变化。通过分析这些光信号的物理变化,可以有效检测光纤所受的外界扰动信号。

光在光纤内传播的过程中,会与光纤材料中的微小粒子发生弹性或非弹性的碰撞,从而产生光散射现象,当一束光通过光纤时,所产生的散射光谱可分为瑞利散射、拉曼散射和布里渊散射^[33],入射光谱与散射光谱如图 2-2。




图 2-2 入射光与散射光谱

布里渊散射和拉曼散射是非线性散射,相对入射光频率分别存在 10Ghz 和 10Thz 的频率偏移;瑞利散射^[34]是线性散射,它是由于光与物质粒子之间的弹性碰撞或光纤本身的不均匀性引起的,是光纤中最主要的损耗散射,具有以下特点^[35]:

- (1) 散射光的频率与入射光相同,没有发生频率偏移,仅改变光的方向。
- (2) 散射光的强度与入射光波长的四次方成反比。

(3) 散射光在不同散射方向上的强度不同,散射光强度与散射方向有关,如公式 2-1:

$$I(\theta) = I_0(1 + \cos^2 \theta) \quad (2-1)$$

其中, θ 为入射光与散射光的方向夹角, I_0 为 $\theta = \pi/2$ 方向的散射光强。

- (4) 散射光的偏振度由 (3) 中的夹角 θ 决定。

根据以上几点特性,瑞利散射常被用来检测光纤中微小的环境变化,如应变、振动和温度变化等, Φ -OTDR 技术基于此原理,通过监测光纤中瑞利散射信号的变化,实现高灵敏度的动态信号探测和定位。

2.2.2 Φ -OTDR 技术

Φ -OTDR 是一种基于瑞利散射原理,使用高相干性的窄线激光器^[36]发出探测光,通过检测瑞利散射光信号的相位变化实现扰动监测的技术。相比传统的仅依赖

散射光强度的 Φ -OTDR 监测方法, Φ -OTDR 能够对光纤沿线的振动、应变和温度变化进行高精度检测, 探测更微小的扰动。

激光器依赖于激活介质内的粒子在特定能级跃迁过程中释放光子, 从而形成高度相干的光束, 影响激光的相干特性的直接因素是光谱宽度, 较窄的光谱宽度可提升干涉效应, 从而增强系统的信号质量和信噪比。因此, 使用窄线宽激光器向光纤中发出的频率为 f , 脉冲宽度为 W 的短脉冲光作为探测光, 在光纤中传播时发生后向瑞利散射, 散射光沿着光纤反向传播被探测器接收。光信号公式如式 2-2:

$$e(t) = \sum_{k=1}^N A_k(t) \exp\left[-\frac{\alpha c T_k}{n} + 2\pi k f(t - T_k)\right] \text{rect}\left(\frac{t - T_k}{W}\right) \quad (2-2)$$

其中, $A_k(t)$ 为第 k 个散射点的瑞利散射光幅度, α 为光纤的衰减系数, c 为光速, T_k 为第 k 个散射点的散射光回到光纤入射端的时长, n 为光纤的折射率, 表示单位长度内光信号损失量, rect 为矩形函数。在光纤中, 两个相邻散射点的相位差与窄线宽光源的频率关系如式 2-3:

$$\varphi_{kl} = \frac{4\pi f n(d_k - d_l)}{c} \quad (2-3)$$

其中 d 为散射点和入射口的距离。当外界扰动发生时, 光纤某一位置的折射率将发生改变, 这一改变作用于瑞利散射光的相位中, 使相邻散射点的相位差发生明显变化, 因此, 通过分析探测器接收信号相邻周期的相位差, 可以实现对扰动信号的精准探测定位。

2.2.3 系统探测原理

光信号探测方法分为直接探测和相干探测^[37], 两种方法都是基于 Φ -OTDR 技术。直接探测指的是直接测量光信号的相位变化, 通过分析瑞利散射信号的相位随时间或位置的变化, 来推测光纤沿线的振动信息。由于受非线性因素影响较大, 所以一般只用于粗略识别是否有振动发生。

相干探测利用本振光与瑞利散射的光信号进行混频, 产生拍频信号, 将原本处于光频率范围的信号转换为相对较低频的信号, 能够精确地获取经过调制的相位信息, 因此本系统使用相干探测监测干扰。

在一次探测中, 激光器发出一次脉冲信号, 接收的散射光信号为:

$$E_m(t) = A_m(t) \exp[j(\omega_m t + \phi_m)] \quad (2-4)$$

本振光的相位为随机相位, 信号表示为:

$$E_n(t) = A_n(t) \exp[j(\omega_n t + \phi_n)] \quad (2-5)$$

混频后的拍频信号频率可以表示为:

$$\omega_k = \omega_m - \omega_n \quad (2-6)$$

因为低频处噪声较强,为提高信噪比,需要将 ω_k 限制为不为0的值,即信号搬移到特定的频率范围,并可以使用窄带滤波器滤除背景噪声,提高系统的稳定性。这种探测方式为外差探测,探测结构如图2-3。窄线宽激光器作为光源,输出连续光被耦合器(Optical Coupler, OC)分为光功率比99:1的两路:一路用于探测信号光,另一路作为本振光。功率为99%探测信号光通过声光调制器(Acousto-Optic Modulator, AOM),将连续光转换为脉冲光,形成探测光脉冲,再通过掺铒光纤放大器(Erbium Doped Fiber Amplifier, EDFA)实现光功率的放大。光脉冲进入光纤后,沿光纤的瑞利散射会形成后向散射信号,经过环形器进入3dB耦合器与本振光混频,由于两束光的频率接近,其相干叠加形成拍频信号,最后将信号通过平衡光电探测器(Balanced Photodetector, BPD)将光信号转换为电信号。




图 2-3 外差探测结构

2.3 信号采集方法

信号采集使用AD9643高速采集芯片,AD9643是一款双通道、14位、采样速率最高达250 MSPS的高速采集芯片,最高支持650 MHz的模拟输入带宽。其低压差分信号(Low Voltage Differential Signal, LVDS)输出接口与FPGA连接,其传输时序如图2-4。




图 2-4 AD9643 时序

在每个时钟周期内，它通过 14 条差分数据线传输 14 位宽的数据，同时采集芯片提供数据时钟输出（Data Clock Output, DCO）用于同步接收端的数据采集，支持双通道交错采样模式，通道一和通道二的数据交错进行传输，当 DCO 处于上升沿时，传输通道 1 的数据；当 DCO 处于下降沿时，传输通道 2 的数据。

光学集成模块输出的电信号将由 ADC 芯片采集后传输至 FPGA 解调。ADC 输出的采集信号为差分信号，在 FPGA 接收端，信号解调前需要先将 14 路差分信号转换为单端信号，差分-单端转换结构如图 2-5。首先由 2.3.1 中的脉冲触发-采集控制模块发出的 trigger 控制数据接收使能，输入的每对差分信号都是相位相反的同一个逻辑信号，接着使用 14 个差分输入时钟缓冲器（Differential Signaling Input Buffer with Selectable I/O Interface, IBUFDS），通过比较这两个信号的电压差来判断逻辑值，并输出相应的单端信号，最后，再经过位拼接方式将 14 路单端信号转成一路串行输出。




图 2-5 差分-单端转换结构

2.4 探测光脉冲触发-采集控制方法

在系统中，根据系统的探测频率和空间分辨率需求，FPGA 端触发控制声光调制器产生的脉冲频率和宽度，进而控制产生拍频信号的重复频率。同时控制 ADC 芯片的实际采集距离。

系统时钟为 clk_{sys} ，发出脉冲光的重复频率为 f_{sample} ，此时一个脉冲光对应系统时钟周期数 N_{total} 为 clk_{sys} / f_{sample} 。在确定系统时钟周期后，还应设定根据脉冲光的宽度确定脉冲置位周期数 N_{pwm} ，脉冲光的宽度计算公式如 2-7：

$$\tau = \frac{2n \cdot \Delta z}{c} \quad (2-7)$$

其中， Δz 为探测的空间分辨率。理论上，脉冲光的探测最长距离约为 $100M \cdot m / f_{sample}$ ，综合考虑实际需求监测距离、硬件的存储、功耗、带宽资源，需

要对 ADC 芯片的实际采集距离作出设定, 和光脉冲触发在同一时钟下, 对应系统时钟周期数为 $N_{trigger}$ 。

在确定以上参数后, 脉冲触发-采集控制结构如图 2-6。通过内部计数器和时钟产生脉冲信号, 计数器计数一个脉冲光对应的, 同时参与计数是否达到和的判断, 输出脉冲宽度调制 (Pulse Width Modulation, PWM) 信号和 ADC 采集控制 trigger 信号, 声光调制器根据接收到的 PWM 脉冲信号将原本的连续光信号调制为周期性的脉冲光信号; 后续采集接收端通过 trigger 的控制实现特定距离的采集。




图 2-6 脉冲触发-采集控制结构

2.5 相位解调原理

在外差相干探测 Φ -OTDR 系统中的信号处理部分, 由于外界扰动会导致光纤的相位变化, 系统需要对回波信号进行解调, 以提取这些相位信息。平衡探测器输出的电信号的强度随相对相位的变化而变化, 电信号强度公式如式 2-7:

$$E_k(t) \propto I_0 + A_0(t) \cos[\omega_k t + \phi(t)] \quad (2-8)$$

其中, I_0 为信号中的直流成分, 平衡探测器已经在一定程度上削弱直流成分, 此时的信号直流较弱。还原光纤的振动信号就是解调上式中相位 $\phi(t)$ 的过程, 通过精确提取回波信号中的相位信息, 恢复传感光纤周围的原始振动信号。系统采用了基于下变频与滤波的 IQ 解调^[38-39]、旋转矢量叠加^[40]、相位解卷绕方法还原原始相位信息。

IQ 解调通过频率转换和带通或低通滤波来提取信号的正交分量, 进而获得相位信息, 实现对传感光纤周围振动信号的重构。输入的信号如式 2-8, 信号分别和频率相同的正余弦函数相乘实现频移。

$$E_k(t) = A_0(t) \cos[\omega_k t + \phi(t)] \quad (2-9)$$

两路信号再通过低通滤波器滤除高频分量, 保留下变频成分:

$$\begin{cases} E_I(t) = \frac{1}{2} A_0(t) \cos[\phi(t)] \\ E_Q(t) = \frac{1}{2} A_0(t) \sin[\phi(t)] \end{cases} \quad (2-10)$$

通过 IQ 解调算法, 振动信号的相位信息已经初步算出, 然而此时的信号仍存在使信噪比降低的干涉衰落^[41], 由于窄线宽激光光源的相干长度远大于系统的测量长度, 导致在光脉冲的脉冲宽度范围内, 各散射点产生的瑞利散射光之间会发生干涉, 这种干涉效应会引起信号强度的锯齿状波动, 造成信号的强度衰落, 使相位的相对分布不稳定, 进而影响相位的解调。

旋转矢量叠加使用几个相同相位的信号补偿衰落信号, 将 IQ 解调的通过低通滤波器后的信号分为几个频率自由度, 每个频率分量都表示为复平面上的矢量, 通过矢量旋转后叠加每个自由度同一时刻的信号并计算均值得到此时的信号强度。

将 IQ 解调后的信号写成向量形式:

$$\vec{e}_s(t) = I_s(t) + jQ_s(t) = A_s(t) \exp[j\phi_s(t)] \quad (2-11)$$

其中 s 为分频自由度。由于相位中存在随机常量, 同一时刻的信号相位角度并不同, 若此时直接叠加向量, 信号强度会受到随机常量的影响, 叠加后的向量相位发生偏移。由于在相同时间下不同频率自由度的信号由振动引起的相位变化, 即相位差是相同的^[42], 所以可以使用相对相位抵消随机相位的影响。在一个处理周期内, 选择第一个点 t_0 时的相位作为基准相位, 其角度可以表示为:

$$\phi_s(t_0) = \arg(\vec{e}_s(t_0)) \quad (2-12)$$

在本处理周期内, 将每个频率自由度的信号所有时刻都旋转 $-\phi_s(t_0)$ 角度, 旋转后的矢量表示为:

$$\vec{e}_s(t_n) = A_s(t_n) \exp[j(\phi_s(t_n) - \phi_s(t_0))] \quad (2-13)$$

此时不同频率自由度的相同时刻的向量旋转角度是相同的。对旋转后对每个自由度相同时刻的向量分 I、Q 两路分别进行叠加, 即可得到此时的两路信号强度, 最后, 通过反正切计算信号相位:

$$\phi(t) = \arctan \frac{E_I(t)}{E_Q(t)} \quad (2-14)$$

旋转后的正交信号通过数字加法器进行矢量叠加求和, 重构出包含完整相位信息的复合信号强度, 该过程有效消除了载波泄露和直流偏置引入的测量误差。最后, 通过相位解卷绕校正序列在某些特定点计算需要补偿的相位^[43], 式 2-15 为校正序列公式:

$$COR(t) = \begin{cases} COR(t-1) - 2\pi & \phi'(t) - \phi'(t-1) > \pi \\ COR(t-1) + 2\pi & \phi'(t) - \phi'(t-1) < -\pi \\ COR(t-1) & -\pi < \phi'(t) - \phi'(t-1) < \pi \end{cases} \quad (2-15)$$

其中 $COR(0) = 0$ ，特定点就是相邻相位主值的绝对值大于 π 的跳跃点，根据相位差的值补偿特定倍数的 2π ，使绝对值限制在 π 内，补偿计算如式 2-16，经过补偿后相位恢复为真实值。

$$\phi(t) = \phi'(t) + COR(t) \quad (2-16)$$

2.6 系统性能

基于以上外差相干探测和解调技术，分布式光纤管道入侵事件监测系统探测、采集、解调性能得到极大提升，其中，与本文研究的声纹识别算法相关的性能指标主要有两个：应变灵敏度和频率响应范围。应变灵敏度表示系统探测的扰动的敏感程度，灵敏度越高，系统对微弱扰动的感知能力越强，获取的振动信号越保真^[44]；频率响应范围代表系统能够传感和监测的声波频率范围，范围表示系统对不同频率声波信号的识别和处理能力。系统性能指标如表 2-1。

表 2-1 系统性能评价指标

性能	指标
应变灵敏度	$88 \text{ p}\varepsilon / \sqrt{\text{Hz}}$
频率响应范围	40Hz-500Hz

其中，在 $88 \text{ p}\varepsilon / \sqrt{\text{Hz}}$ 的应变灵敏度下，系统能够还原精确还原 55 Hz 和 200 Hz 的微弱信号^[45]。同时，系统支持 40Hz–500Hz 的频带检测，管道入侵事件的信号频谱分布集中在 100Hz 左右，重频设置在 1kHz，指标覆盖管道入侵事件的主要频谱成分，因此系统指标符合声纹识别的需求。

2.7 本章小结

本章阐述了入侵事件监测系统的信号探测、解调原理，探测部分基于瑞利散射和 Φ -OTDR 技术，光学集成模块由窄线宽激光器、声光调制器、环形器、耦合器、平衡光电探测器构成；解调部分包括 IQ 解调、旋转矢量叠加、相位解卷绕方法。分析了基于以上技术的系统的性能指标，符合后续声纹识别对于探测灵敏度和频率响应范围需求。

第三章 DAS 信号的声纹识别算法研究

第二章阐述了用于声纹识别的振动信号采集方法，系统获取的信号基本还原原始相位信息，可直接用于振动信号的分类任务。

声纹识别的目的是区分管道事件的油夯机施工、挖机挖掘、人工挖掘三类信号。本章首先概述探测信号声纹识别的处理流程，针对三类事件特征设计训练与识别阶段采用的特征提取方法，分析模型的识别实时性能确定分类模型，通过实验研究梅尔滤波器数量、梅尔倒谱系数中引入动态参数、高斯模型数量对识别率的影响，验证 GMM-UBM 模型在识别实时性和计算效率等方面的性能。

3.1 声纹识别的基本流程

声纹识别通常包括两个阶段：模型训练和特征识别。在模型构建阶段，系统通过特征提取对海量声纹样本进行特征解构与规律挖掘，形成具有身份鉴别能力的声纹模板库。进入识别阶段时，系统对输入语音进行实时特征映射与相似度比对，实现身份信息的鉴别。图 3-1 展示了声纹识别的训练和识别流程。




图 3-1 声纹识别的训练和识别流程

在训练阶段，系统首先对大量的事件声音数据进行注册，利用声学特征提取算法从中提取出事件的声纹特征，包括声音信号的频谱、共振峰、短时谱包络等，这些特征能够有效区分不同目标的声音。在特征提取后，使用机器学习或深度学习算法对这些特征数据进行模型训练，通过训练过程建立起每个事件的语音模型。这一阶段通过优化算法，使得模型能够充分表示事件的声纹特征，提高后续识别的准确性和鲁棒性。

识别阶段中，当系统接收到测试声音信号时，首先对该声音信号进行相同的特征提取过程，从中获得声音信号的声纹特征。随后，将提取到的特征与之前训练阶段建立的事件模型进行比对和匹配。通过计算模型间的相似度或差异性进行打分，即确认该声音信号所属的事件。识别过程的核心是特征比对和评分机制，系统会根

据特征的相似性对每个可能的事件模型打分，并最终选出得分最高的模型作为识别结果。

综上，声纹识别准确率和实时性由特征提取方法和模型决定。

3.2 特征提取方法及对比分析

对系统解调输出的振动信号直接实施特征提取，本文选取三种主流的特征提取方法，通过分析三类信号的时频特征比较算法在管道事件分类中的适用程度。

3.2.1 线性预测系数

线性预测系数(Linear Prediction Coefficients, LPC) 提取的基本原理是模拟发声结构，通过建立信号模型来捕捉信号的短时相关性，反映发声结构的共振峰特性。如图 3-2 的声音产生模型，LPC 将声音产生过程表示为声源激励与时变全极点滤波器的级联系统，声源激励可以是周期或非周期信号，滤波器对产生的激励信号进行频谱整形产生声音信号。




图 3-2 声音产生模型

线性预测系数是基于此模型提出的，全极点滤波器的系数取决于发声结构本身的特性， p 阶滤波器响应表达式如式 3-1：

$$H(z) = 1 - \sum_{i=1}^p a_i z^{-i} \quad (3-1)$$

其中， a_i 为第 i 个滤波器系数。在时域中表现为声音信号临近采样点间具有相关性，即一个声音信号的当前样本值，可以使用过去的若干个样本值或它们的线性组合来近似估计，并使用最小均方误差准则最小化预测值与实际采样值之间的误差，调整预测系数，直到确定一组唯一的预测系数。

对于给定时刻采样的声音信号 $x(n)$ ，可以用前 p 个样本的采样的线性组合来表示：

$$x(n) = \sum_{i=1}^p a_i x(n-i) + v(n) \quad (3-2)$$

其中，加权项为预测系数和过去样本值， $v(n)$ 为线性预测误差。根据上式第 n 个样本值的预测误差均方误差的期望值可以表示为：

$$E_n = \sum_m v_n^2(m) = \sum_m [x_n(m) - \sum_{i=1}^p a_i x_n(m-i)]^2 \quad (3-3)$$

根据最小均方误差准则计算预测系数，求使均方误差的期望值最小的系数 a_i ，将期望对系数求偏导：

$$\frac{\partial E}{\partial a_i} = 0 (1 \leq i \leq p) \quad (3-4)$$

求解上述等式可以将计算偏导后的加权式写成 Toeplitz 矩阵，使用 Durbin 算法^[46]解该矩阵，最后得到预测系数 a_i ，用系数与过去的声音信号线性组合的差分方程表示预测声音信号：

$$\hat{x}(n) = \sum_{i=1}^p a_i x(n-i) = -a_1 x(n-1) - a_2 x(n-2) - \cdots - a_p x(n-p) \quad (3-5)$$

线性预测系数是根据物体本身的发声特点建模，所以具有较高的鲁棒性，且其计算量较小，可以用于分布式光纤传感系统的实时特征提取。

3.2.2 线性预测倒谱系数

线性预测倒谱系数（Linear Prediction Cepstrum Coefficient, LPCC）和 LPC 系数同样描述共振峰特性，是 LPC 在倒谱域的表达：

$$H(z) = \frac{1}{1 - \sum_{i=1}^p a_i z^{-i}} \quad (3-6)$$

声学信号本质上是声道滤波器与激励源信号的卷积输出，LPCC 通过倒谱分析，在保留声道结构特征的同时，分离语音产生过程中的激励分量，表示声道响应特征，通过数学变换消除激励信号对频谱特征的影响。这种方法能够抑制激励信号的随机性干扰，增强声学特征在复杂工况下的稳定性，为后续识别提供更具判别力的参数表征方式。

线性预测倒谱系数可以由 LPC 的系数直接推导，如式 3-7：

$$C_{LPCC}(n) = C_{LPC}(n) + \sum_{i=1}^p \frac{n-i}{n} C_{LPCC}(n-i) C_{LPC}(i) \quad (3-7)$$

同时，由公式 3-6 的倒谱域传递函数，也可以得到倒谱系数 $c(n)$ 和 LPC 系数 a_n 的关系，如公式 3-8：

$$\begin{cases} c(1) = a_1 \\ c(n) = a_n + \sum_{i=1}^{n-1} (1 - \frac{i}{n}) a_i c(n-i), 1 < n \leq p \\ c(n) = \sum_{i=1}^p (1 - \frac{i}{n}) a_i c(n-i), n > p \end{cases} \quad (3-8)$$

通过分析传递函数的零极点分布情况可以得到， $c(n)$ 从低时域延伸到高时域，而传递函数只分布在低时域，而声音信号所携带的语义信息主要体现在声道的传递函数上，所以 LPCC 只需要取倒谱的 10-16 个系数就能较好地描述语音信号的共振峰特性。

3.2.3 梅尔倒谱系数

梅尔频率倒谱系数(Mel-scale Frequency Cepstral Coefficients, MFCC)是根据人耳听觉特性提出的，通过滤波器模拟耳蜗对不同频率的响应，是近十年来声纹识别和语音识别领域中最为广泛应用的特征提取方法^[47]。MFCC 和 LPCC 也是语音识别中反映短时谱包络时采用的主要特征参数^[48]。

人类听觉系统的有效感知频段为 20Hz 至 20kHz，但其对赫兹标度的频率感知呈非线性特性，人耳对不同频率的声波有不同的听觉敏感度，随着频率增加呈对数增长，即对低频声波的敏感度高，随频率升高敏感度衰减。梅尔频率倒谱系数根据该听觉机制，通过式 3-9 将线性频率域 f 映射至梅尔标度域 $M(f)$ ，该非线性标度与人耳听觉敏感度变化趋势相匹配，能更精确地描述声学信号的感知特征。

$$M(f) = 2595 \lg(1 + \frac{f}{700}) \quad (3-9)$$

转换后的映射关系如图 3-3，可以发现人耳对低频声音的分辨率明显高于对高频声音的分辨率，当频率较低时，Mel 值随频率的变化速度较快，曲线陡峭，而在频率较高时，Mel 值的变化趋于平缓，曲线的斜率逐渐减小，因为在人耳内低频声音的行波传递距离比高频声音更长，所以通常低频声音更容易掩蔽高频声音，人耳对低频音调更为敏感，而对高频音调的感知较为迟钝。同时，当两个响度不同的声音同时作用于人耳时，响度较大的频率成分会影响对响度较小的频率成分的感知，

使后者变得难以察觉,这种现象被称为掩蔽效应,低频区域声音掩蔽的临界带宽比高频区域更窄。




图 3-3 Mel-Hz 映射关系

根据响度和频率的掩蔽特性,梅尔倒谱是在低频到高频的频带范围内,根据临界带宽的大小,由密到疏设计一组带通滤波器,对信号频谱进行分频滤波处理,并消除谐波的作用,突显原先语音的共振峰,图 3-4 为梅尔倒谱提取流程,由于声音信号具有非平稳特性,直接对整个信号进行分析会丢失局部特征,因此需要将信号分割为短时帧,用于后续对声音信号的短时分析。首先,对输入的声音信号进行预处理的分帧操作,接着,分帧后对每一帧信号施加窗函数,通过对帧边缘信号进行平滑衰减,确保帧内信号和边缘处的连续性,同时保留信号的主要频谱特征,避免频谱泄漏问题。




图 3-4 梅尔倒谱系数提取流程

由于检测的三种管道事件声音频率分布在低频,本文采样重复频率取 1kHz,帧长为 32ms,加窗使用汉宁窗。每一帧均可以看作一个短时平稳的过程,对语音序列做快速傅立叶变换 (Fast Fourier Transform, FFT) 将语音信号 $x(n)$ 从时域变换到频率域,得到频域信息为:

$$X(k) = \sum_{n=0}^{N-1} x(n) e^{-j \frac{2\pi jnk}{N}}, 0 \leq k \leq N-1 \quad (3-10)$$

其中, N 为变换点数, k 为频率点。再对频谱求幅度平方得到幅度谱, 将幅度谱通过梅尔频率滤波器组 $H_m(k)$, 每个滤波器都是一个三角滤波器, 公式如 3-11:

$$H_m(k) = \begin{cases} 0, & k < f_{m-1} \\ \frac{k-f_{m-1}}{f_m-f_{m-1}} & f_{m-1} < k < f_m \\ \frac{f_{m+1}-k}{f_{m+1}-f_m} & f_m < k < f_{m+1} \\ 0 & k > f_{m+1} \end{cases} \quad m = 0, 1, \dots, M-1 \quad (3-11)$$

其中, f_m 为第 m 个三角滤波器的通带截止频率, 最高为重频的一半, 因此滤波器组的分布和重频相关。如图 3-5, 图 (a) 为人声识别领域的梅尔滤波器, 重频可以达到 40kHz, 滤波器带宽随频率增加而增大, 分布逐渐稀疏, 这意味着低频区域的滤波器数量更多, 能够更细致地捕捉低频信息, 而高频区域的滤波器数量较少, 以减少计算复杂度。在非人声识别领域, 如图 (b), 管道入侵事件识别为 1kHz 重频滤波器, 分布在低频的每个滤波器接近等高, 可以弥补频率越高, 人耳听觉越迟钝这一缺陷。




图 3-5 梅尔滤波器。(a) 人声识别 40kHz 重频的滤波器; (b) 入侵事件识别 1kHz 重频的等高滤波器

接着对上一步滤波器输出取对数能量:

$$L_m = 10 \log_{10} \left(\sum_{k=0}^{N-1} |X(k)|^2 H_m(k) \right), 0 \leq m \leq M-1 \quad (3-12)$$

最后对结果进行离散余弦变换 (Discrete Cosine Transform, DCT), 如公式 3-13:

$$C_k = \sum_{m=0}^{M-1} c(k) L_m \cos\left(\frac{(2m+1)k\pi}{2M}\right), k = 0, 1, \dots, N-1 \quad (3-13)$$

$c(k)$ 是常数, 如式 3-14。离散余弦变换是一个特征正则化的过程, 使不同维度间相互独立, 为训练模型中更新协方差过程和识别中打分判决过程减少计算量。

$$c(k) = \begin{cases} \sqrt{\frac{1}{N}} & k = 0 \\ \sqrt{\frac{2}{N}} & \text{else} \end{cases} \quad (3-14)$$

由于音频信号具有较强的低频成分, DCT 能将这些成分集中在梅尔倒谱系数的低维部分, 为运算降维、提高模型的计算效率提供了基础, 本文取计算结果的前 12 维^[49], 图 3-6 为 35s 的油夯机施工作业声音信号 12 维梅尔倒谱系数, 是 12*2186 特征矩阵。




图 3-6 油夯机施工作业声音信号 12 维梅尔倒谱系数

3.2.4 动态差分系数

在得到 MFCC 参数后, 由于倒谱参数 MFCC 是对声音信号在傅里叶变换的基础做了数据的抽取与变换, 只反映了信号的静态特征, 一般为提高系统的识别性能, 将语音动、静态特征结合起来。

动态特征可以用静态特征的一阶、二阶差分谱来描述。一阶差分体现了当前语音帧与后一帧之间的关系, 体现帧与帧 (相邻两帧) 之间的联系, 公式如式 3-15:

$$\Delta x[n] = x[n+1] - x[n] \quad (3-15)$$

二阶差分表示的是一阶差分与一阶差分之间的关系, 即前一阶差分与后一阶差分之间的关系, 体现到帧上就是相邻三帧之间的动态关系, 二阶差分公式如式 3-16:

$$\Delta^2 x[n] = x[n+2] - 2x[n+1] + x[n] \quad (3-16)$$

在得到 MFCC 参数和一阶、二阶差分参数后, 将三类系数拼接输出, 得到 36 个特征向量。

3.2.5 特征提取方法对比分析

在选择合适的特征方法时，首先分析人工挖掘、油夯机施工、挖机挖掘信号的时域和频域特征，根据其分布规律选择能够区分三类特征的方法。本文选择典型的三类挖掘信号，从时域和频域角度分析三类信号的特征。

图 3-7 为三类信号的 15s 时域波形和时域波形对应的频域波形，其中，人工挖掘信号实际通过人工敲击模仿实际挖掘行为产生。




图 3-7 管道信号时域、频域图。(a)、(d) 人工挖掘；(b)、(e) 挖机挖掘；
(c)、(f) 油夯机施工

从时域波形的分析可以看出，三类信号的时域波形存在显著差异，图 (c) 中油夯机信号的幅值明显大于挖机信号的幅值，而图 (b) 挖机信号的时域波形表现出较强的随机性和不规则性，波动幅度和形态均不稳定，呈现出较为复杂的变化特征。相比之下，图 (a) 的人工挖掘信号的时域波形分布则相对规律，每次产生的信号幅值在时间轴上逐渐衰减，表现出典型的递减趋势和较为平滑的波形。在频域中，挖机、油夯机频谱分布范围比人工更大，但三类信号的频谱均集中分布在 0-

100Hz 的低频段。为进一步反映三类信号在低频段内频谱分布上的差异, 本文将分析分段频域能量, 首先设定 10Hz 频率步长, 将信号全频段划分为等带宽子频带, 随后计算各子频带内积分能量值, 将频谱能量进行归一化处理。在低频段能量分布特征如图 3-8。图 (a) 中的人工挖掘信号频谱能量在 0-100Hz 内均有分布, 其中有 51% 分布在 20-40Hz; 而图 (b) 的挖机信号的能量分布主要在 0-30Hz, 有 70% 分布在 0-10Hz; 图 (c) 中的油夯机信号频谱能量主要分布在 0-60Hz, 在 30-40Hz 内占比 66%。综上, 挖机信号的频谱分布较其他两类分布差别较大, 挖机和人工信号的能量分布相近而占比不同, 可以按照 20-30Hz 和 30-40Hz 两个频段区分。




图 3-8 信号频谱能量分布。(a) 人工挖掘; (b) 挖机挖掘; (c) 油夯机施工

LPC 和 LPCC 通过最小化线性预测误差来估计声音信号的声道参数, 通常通过对信号进行反演来估计线性预测系数, 上文已经分析, 挖机挖掘和油夯机施工信号的波形并不具有强规律性, 表现为非周期性的复杂波形, 其振幅随时间变化较大, 在频域上, 频谱特性并非线性分布, 尤其是在低频区域, 需要特征提取方法能更详细地描述低频分布, 而 LPC 和 LPCC 的描述能力有限, 估计能力不足以表现信号更具体的特征。

MFCC 能够模拟人耳听觉的非线性, 采用梅尔刻度滤波器组进行频域分析。其中, 梅尔滤波器的重叠式设计可有效提取信号的局部频域特征, 尤其是在低频区域, 在图 3-5 (b) 中, 12 个梅尔滤波器的 0-100Hz 部分设置了 3 个滤波器, 对三类信号的低频能量分布实现较高分辨率表示。

三类信号在梅尔滤波后的能量分布如图 3-9, 能量分布呈现低维向高维递减趋势, 其中前三个维度分别对应梅尔滤波器中的前三个滤波器的滤波输出, 三类信号在数值上有明显的区分度, 同时, 梅尔滤波器对更高维度能量也有一定的区分能力。

因此，从实际信号的时域、频谱特性和系统的鲁棒性考虑，选择 MFCC 作为特征提取参数。MFCC 结合一阶、二阶动态参数的识别效果将在 3.5 节验证。




图 3-9 三类信号的前 12 维梅尔滤波能量分布

3.3 识别模型对比分析

在完成特征提取后需构建目标事件的声学特征模型，考虑到 DAS 系统具有多通道并发探测，实时产生海量监测数据的特性，需采用轻量化建模方法以降低计算负载。模型选择需兼顾识别精度与计算效率，具体为模型参数规模可控、内存占用量小，并适配多通道场景下的快速识别需求。

第一章介绍了声纹识别方法有模板匹配、概率模型、深度学习模型方法，模板匹配法虽然计算效率较高，但其识别性能与模型库规模呈负相关关系^[50]，随着模型库规模扩大，匹配计算量线性增长，导致识别速度下降；人工神经网络方法模拟生物神经系统的并行处理机制，具有较强的模式识别能力，然而该方法存在训练复杂度高的问题，具体表现为训练周期长，且在多目标识别场景下模型收敛困难。

高斯混合模型-通用背景模型（Gaussian Mixture Model-Universal Background Model, GMM-UBM）作为一种基于概率密度估计的统计建模方法，在说话人识别领域已展现出较高的识别性能^[51]。同时，该模型在实时处理中具有独特优势：当采用 12 维 MFCC 特征参数、建模的高斯混合阶数设置为 8 时，文献[52]中实验数据显示，针对 22.05kHz 采样频率的 10s 语音信号，特征提取与模式识别的全流程平均处理时延为 31.63ms。文献[53]中进一步证明了特征提取阶段的运算开销占主导地位，在 16kHz 采样频率下，7.5s 语音信号的特征提取与识别的耗时比约 1: 310。当信号时长与重频降低时，单次识别耗时会随之缩减，经理论推导，在 16kHz 重频下，对于 7.5s 信号的单次识别耗时将压缩至 0.1ms 以下。

入侵事件监测系统的重频为 1kHz，结合图 3-7 的三类信号时域波形分析，在 7.5s 时间内至少包含一个信号周期，本文用于识别的信号时长将小于 7.5s。以监测 500 通道为例，模型整体识别时延经估算可控制在 50ms 内。

基于上述时延性能与计算效率的分析，GMM-UBM 模型满足系统对于实时性的监测要求，故选定为本文的识别模型。

3.4 基于多分类判决的 GMM-UBM 声纹识别模型

GMM-UBM 是 GMM 模型的改进模型，基于 GMM 的强拟合能力，通过使用非目标事件（如空采背景、车辆行驶、其他机器作业等）的声音特征向量，建立通用 UBM^[54]作为目标事件的先验模型。

由于通用背景模型中引入了干扰声音和背景噪声，所以在相同环境下，降低了噪声对识别效果的影响，同时作为先验模型，UBM 已对语音特征在空间分布的概率模型给出一个良好的预先估计，所以无需再收集目标事件上千条目标语料。尤其适用于对于发声较人声更稳定的机器语料，这样就减少了实际训练过程中的数据量、参数量，在上位机可以快速训练收敛和解码计算。

GMM-UBM 声纹模型的训练及识别流程如图 3-10 所示。训练过程是非目标事件的 UBM 和三类目标事件的 GMM 建模过程：首先进行 UBM 建模，其过程就是使用 GMM 拟合各维特征参数的分布过程，在使用 EM（Expectation-Maximization Algorithm）算法训练所有非目标事件特征后，得到一个 UBM 模型。接着，再基于事件的声纹特征向量，在 UBM 上进行最大后验概率（Maximum a Posteriori Probability, MAP）算法的自适应参数微调，实现目标事件的 GMM 模型估计。




图 3-10 GMM-UBM 训练及识别流程

识别就是结合识别信号的特征向量、目标事件 GMM、背景事件 UBM，使用多分类的对数似然比（Log-Likelihood Ratio）打分判决，给出识别的事件的过程。

3.4.1 高斯混合概率密度函数

GMM 是多个高斯分布函数的线性组合，其概率密度函数是将 M 个分量密度各赋权重并加和，可以拟合出任意类型的分布。混合概率密度表示为：

$$p(x|\lambda) = \sum_{i=1}^M w_i g(x|\mu_i, \Sigma_i) \quad (3-17)$$

其中， x 是每帧特征向量， λ 是高斯混合模型表示的每个事件的声纹特征分布的参数集合， $\lambda_i = (w_i, \mu_i, \Sigma_i)$ ， w_i 是混合权重分量， $g(x|\mu_i, \Sigma_i)$ 为第 i 个高斯分量的概率密度函数， μ_i 和 Σ_i 分别是其均值和协方差，其公式如式 3-18：

$$g(x|\mu_i, \Sigma_i) = \frac{1}{(2\pi)^{\frac{M}{2}} |\Sigma_i|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)} \quad (3-18)$$

每一帧语音的特征向量可以视为一个正态分布，语音特征在特征空间中的分布由多个高斯分量线性叠加而成，通过为每个高斯分量分配一个非负权值并满足总和为 1 的约束条件，形成一个 GMM 模型。

模型的训练过程就是模型的训练本质是不断迭代优化参数集，确定每个正态分布的均值、协方差以及对应权值的最优参数的过程，使模型能够最大程度地拟合训练数据的分布特性。

3.4.2 EM 算法

GMM-UBM 首先使用非目标事件声音训练通用背景的高斯模型，对高斯混合模型的各个参数进行估计，得到一组参数即权重、均值、协方差用来表征非目标事件。使用最大期望算法 EM^[55] 对 GMM 的似然函数进行最大值估计，这是一种在已知混合分布的高斯模型数量的前提下，估计各个成分分布参数的通用方法，其计算流程如图 3-11。




图 3-11 EM 算法更新参数流程

更新分为两步，分别是 E 的计算期望步骤，M 的最大化步骤，每次迭代都交替进行两步骤，寻找最佳 λ ，即权重、均值、协方差，使似然函数 $p(x|\lambda)$ 最大，找到使用多个高斯模型对事件特征的最佳表示，EM 计算过程为：

1) E-step: 根据当前的参数估计值计算高斯成分 i 对某时刻 t 观测数据 x_t 的响应度，即每个数据属于各个高斯成分的概率，公式如式 3-19。

$$\rho_{it} = \Pr(i | x_t, \lambda_i) = \frac{w_i g(x_t | \mu_i, \Sigma_i)}{\sum_i^M w_i g(x_t | \mu_i, \Sigma_i)} \quad (3-19)$$

高斯分量 $i=1,2,\dots,M$ 。在这一步骤，算法通过估计每个数据点属于某一分布成分的后验概率，构建变量的期望值。

2) M-step: 计算新一轮迭代的各个高斯成分的参数，使得似然函数最大化。更新均值：

$$\hat{\mu}_i = \frac{\sum_{t=1}^T \rho_{it} x_t}{\sum_t \rho_{it}} \quad (3-20)$$

更新协方差：

$$\hat{\Sigma}_i = \frac{\sum_{t=1}^T \rho_{it} (x_t - \hat{\mu}_i)^2}{\sum_t \rho_{it}} \quad (3-21)$$

更新权值：

$$\hat{w}_i = \frac{\sum_t \rho_{it}}{T} \quad (3-22)$$

其中，各类向量数量为 T 。EM 步骤是基于给出高斯成分的参数后进行迭代优化的，所以需要有一个方法先确定初始参数。

3.4.3 K-means 迭代初始化

EM 算法迭代的初值 λ_0 由 K-means^[56] 算法确定，它是聚类的一种，流程如图 3-12。其基本思想是在每次迭代时，利用最小距离准则，通过最小化数据点到聚类中心的欧氏距离来划分数据。每一次迭代会根据当前的簇中心重新分配数据点的类别，使得所有数据点到所属簇中心的总距离和不断减小，最终收敛到局部最优解。




图 3-12 K-means 算法迭代流程

算法的聚类中心迭代流程分为五个步骤：

- 1) 选取所有特征中的任意 M 个矢量作初始聚类中心，设置量化失真阈值 δ 。
- 2) 数据共有 M 个聚类，对于一个特征向量 x_k ，计算其与每个中心的欧氏距离，根据最小距离准则 $|x_k - z_i(m)| \leq |x_k - z_j(m)|$ 给出距离最小的类，从而将 x_k 归于第 k 类。

- 3) 更新聚类中心， N_i 为第 i 类中的特征向量个数。

$$z_i(m+1) = \frac{1}{N_i} \sum_{x_k \in z_i(m)} x_k \quad (3-23)$$

- 4) 若更新的聚类中心和上一中心的欧氏距离 $|z_i(m+1) - z_i(m)| \geq \delta$ ，则转到 2) 继续迭代。

- 5) 在聚类结束后，更新 GMM 模型初始参数，本文聚类迭代更新次数为 128 次。

$$w_i = \frac{N_i}{T} \quad (3-24)$$

$$\mu_i = \frac{1}{N_i} \sum_{x_k \in z_i} x_k \quad (3-25)$$

$$\Sigma_i^2 = \frac{1}{N} \sum_{x_k \in c_i} (x_{ik} - \mu_{ik})^2, k = 0, 1, \dots, T-1 \quad (3-26)$$

EM 算法会基于该初始化结果，进一步优化参数，估计数据的潜在分布，训练出非目标事件的 UBM 模型，然后，再使用目标事件的特征向量对 UBM 模型进行参数调整，建立目标事件的 GMM 模型。

3.4.4 MAP 自适应算法

调整 UBM 模型参数，建立目标事件模型使用 MAP 算法，利用贝叶斯学习^[57]（Bayesian Learning）理论，将 UBM 的先验信息与目标事件的特征相结合实现自适应。

文献[58]分析了使用 MAP 自适应算法的模型使识别阶段的计算复杂度明显降低。当评估包含 M 个分量的 GMM 时，单个观测值的似然度主要由少数的邻近分量贡献，使评分过程采用比直接评估 GMM 模型与 UBM 模型更快。自适应过程如图 3-13。此过程调整 UBM 中有目标事件特征映射的区域，使用依赖混合参数将 EM 算法计算的新参数和 UBM 对应区域参数融合。




图 3-13 目标事件建模自适应过程

MAP 算法主要分为两部分。第一部分为估计目标事件特征数据基于 UBM 中每个高斯分量的充分统计量（Sufficient Statistics），包括特征序列来自各个分量 i 的频数 N_i 、均值期望 $E_i(X)$ 和方差期望 $S_i(X)$ ，用来计算高斯混合模型的权重，均值和方差，第一部分具体过程如下：

1) 根据给定 UBM 模型和目标事件的特征序列 $X = \{x_1, \dots, x_T\}$ ，计算 UBM 分量模型 i 对特征向量 x_T 的响应度 $P_r(i | x_t, \lambda_i)$ ，也就是特征向量 x_T 来自 UBM 第 i 个分量的概率，公式同 EM 算法的 E-step。

2) 使用 $P_r(i | x_t, \lambda_i)$ 计算三个充分统计量。

频数，也是各特征向量来自 UBM 分量 i 的概率和：

$$N_i = \sum_{t=1}^T P_r(i | x_t, \lambda_i) \quad (3-27)$$

均值期望：

$$E_i(X) = \frac{1}{N_i} \sum_{t=1}^T P_r(i | x_t, \lambda_i) x_t \quad (3-28)$$

方差期望：

$$S_i(X) = \frac{1}{N_i} \sum_{t=1}^T P_r(i | x_t, \lambda_i) x_t^2 \quad (3-29)$$

第二部分为使用数据依赖混合参数 α_i ，把新估计的充分统计量和 UBM 的充分统计量结合得到最终的关于目标事件的 GMM 参数估计。

权值：

$$\hat{w}_i = \alpha_i \frac{N_i}{T} + (1 - \alpha_i) w_i \quad (3-30)$$

均值：

$$\hat{m}_i = \alpha_i E_i + (1 - \alpha_i) m_i \quad (3-31)$$

协方差：

$$\hat{\Sigma}_i = \alpha_i S_i + (1 - \alpha_i) ((\sum_i + m_i^2) - \hat{m}_i^2) \quad (3-32)$$

其中 $\alpha_i = N_i / (N_i + \lambda)$ ， λ 是固定的相关因子，一般取值为 8-20，本文取 16。使用依赖混合参数融合的过程避免了模型的过拟合^[59]。

3.4.5 单阈值对数似然比判决

事件的特征识别是一个打分判决的过程，打分使用 LLR 对声音片段的特征参数 X 和训练时生成的第 i 个目标事件的 GMM 模型判定， X 是否属于该类型事件，公式如 3-30：

$$\Lambda_{spk}(X) = \log p(X | GMM_i) - \log p(X | UBM) \quad (3-33)$$

单阈值判决通过设定一个固定的阈值来判断测试样本是否属于某个类别，若样本的 $\Lambda_{spk}(X)$ 最大值超过该阈值，则判定为该最大值对应类别；否则拒绝分类，将其归为非目标事件。

3.4.6 多阈值分类判决

原模型的判决模块使用单阈值判决机制，这种方法简单直接且计算效率高，适合对分类结果要求明确的场景。然而，这种方法的局限性在于，当训练时多个类别的 LLR 值分布差异较大时，单阈值可能无法很好地适应所有类别的分类需求，导致低阈值类别的样本被过度拒绝，使得整体拒绝率升高。

本文使用多分类判决进行改进，在判定前先对每个事件设定一个阈值，阈值的确定和计算 3.4.2 节中的等错误率相关，这是一个通过设定不同阈值来确定最佳等

错误率的寻优过程，当等错误率达到最低时，对应的阈值选定为该事件的最优打分判决阈值。如图 3-14，三个事件分别对应三个阈值，由大至小分别为 thre_max 、 thre_medium 、 thre_min ，通过逐级比较，判断 $\Lambda_{\text{spk}}(\mathbf{X})$ 中的最大值所属的阈值区间，若该最大值位于 thre_max 及以上区间，则判定为 thre_max 对应事件；若介于 thre_medium 与 thre_max 之间，则归为阈值为 thre_medium 的事件；若处于 thre_min 与 thre_medium 范围内，则属于第三类事件；若所有分数均低于 thre_min ，则拒绝分类并标记为非目标事件。




图 3-14 判决示意图

3.5 实验和结果分析

3.5.1 数据集构建

为验证所述特征提取方法 MFCC 与 GMM-UBM 识别模型在管道入侵事件监测中的实际应用效果，将系统的采样率设定为 1 kHz，并在仪陇同段测试管道上多次采集振动信号数据。目标事件信号分为三类：人工挖掘、油夯机施工、挖掘机挖掘，非目标事件信号包括：空采背景、车辆行驶和其他机械作业的干扰噪声。对振动信号数据在时域上以 3 秒/样本为单位进行划分，各类整理后的数据样本数量统计如表 3-1 所示：

表 3-1 管道入侵事件时域样本集的样本数据构成

事件类型	挖机挖掘	油夯机施工	人工挖掘	非目标事件
样本数量	749	710	713	1306

将数据样本集按照训练集、测试集、验证集 6:2:2 的比例分割。划分后的训练集主要用于模型的训练，测试集被用于训练模型的性能评估，验证集不参与分类模

型的训练，只用于训练完成后模型泛化能力的评估测试。本文的识别结果均为验证集的测试结果。

在构建信号时域数据集后，首先需要进行特征提取，计算出 MFCC 特征值，提取的特征分别用于 UBM 模型以及三类目标事件的 GMM 模型的训练和测试中。

3.5.2 识别效果评价

1. 等错误率

本文使用声纹识别中常用的等错误率^[60]（Equal Error Rate, EER）评估模型的识别性能，EER 是错误拒绝率（False Rejection Rate, FRR）和错误接受率（False Acceptance Rate, FAR）相等时的错误率值。FRR 和 FAR 是在预测类别与实际类别的关系中错误接受和错误拒绝的数量占对应同类预测关系的比例，预测关系类别如表 3-2。

表 3-2 预测关系类别

预测类别	真实类别	
	0	1
0	正确拒绝（True Negative,TN）	错误拒绝（False Negative,FN）
1	错误接受（False Positive,FP）	正确接受（True Positive,TP）

FRR 为错误拒绝案例在所有拒绝案例中占的比例。公式如式 3-31：

$$FRR = \frac{FN}{FN + TN} \quad (3-34)$$

FAR 为错误接受案例在所有接受案例中占的比例。公式如式 3-32：

$$FAR = \frac{FP}{FP + TP} \quad (3-35)$$

从高到低调整 LLR 的分类阈值，当 FAR 和 FRR 相等时，表明系统的错误接受和错误拒绝的案例数量达到了平衡，因此，EER 的值越低表明错误案例越少，模型的识别性能越好。

2. 识别速度

模型识别速度是指模型处理一定量数据所需的时间，体现识别的实时性和算法的复杂度，在本文的基于 DAS 系统的管道入侵事件监测系统中，选择模型对 500 个通道数据处理速度进行判断，500 个通道对应的 5km 距离基本满足系统对监测距离的需求。

同时本文还使用模型文件大小作为复杂度的评价标准，较小的模型通常意味着较低的复杂度，更适合在资源受限的嵌入式设备或实时系统中部署。

3.5.3 对梅尔滤波器数量的分析

滤波器数量对识别结果存在非单调性影响，并非数量越多性能越优。过多的滤波器将增加计算复杂度，导致模型训练和推理的时间成本上升，同时可能引入冗余信息，引发过拟合问题，反而降低模型的泛化能力。反之，滤波器数量过少则难以有效提取语音信号的细节特征，造成关键频段信息缺失，导致识别准确率下降。本文分别设置梅尔滤波器数量为 12、16、20、24、28、32，分析梅尔滤波器数量对实验的等错误率的影响，如图 3-15。




图 3-15 各类型事件等错误率、滤波器数关系曲线

滤波器数为 32 时，人工和挖机挖掘等错误率明显较其他数量高；在 12 至 28 区间内，三类事件的等错误率曲线变化较平缓，系统识别性能的变化并不剧烈，且等错误率分布的最低点并不集中；滤波器数为 16、20 和 24 时分别对应的挖机挖掘、人工挖掘和油夯机施工的等错误率最低，进一步比较每个点对应的三类错误率总和可以发现，在滤波器数量为 16 时，总错误率最低，为 0.1991，同时三类目标事件的等错误率未出现明显的偏高，各事件中分布均衡，表明 16 个滤波器在全局判别力与类别特异性之间达到最佳平衡，既能有效降低整体误判概率，又避免了因过度适配某类事件而引发其他类别性能退化的问题。因此本文设置滤波器数量为 16，作为后续实验的参数配置。

3.5.4 对动态参数的分析

由于 DCT 变换已将倒谱系数集中在低频部分,为降低训练和识别的数据量和 FPGA 传输倒谱系数的带宽压力,本文考虑将系数降维处理,此处进一步分析梅尔倒谱系数的动态参数对识别结果的影响,表 3-3 为梅尔倒谱系数和加入一阶、二阶动态参数的识别结果:

表 3-3 MFCC 及加入动态参数的等错误率

参数	等错误率			总等错误率
	人工挖掘	挖机挖掘	油夯机施工	
MFCC	0.0796	0.0482	0.0713	0.1991
MFCC + Δ	0.0824	0.0906	0.1002	0.2732
MFCC + Δ + Δ^2	0.0568	0.0801	0.0624	0.1993

实验结果表明,当 MFCC 特征引入一阶动态参数后系统识别性能有所降低,总等错误率增加 0.0741,尤其在挖机挖掘、油夯机施工事件上,等错误率增加 0.0424 和 0.0289;当同时引入一阶、二阶差分参数时,总等错误率微降 0.0002,但总体来说,加入一阶、二阶动态参数后,识别性能提升较不明显,且对挖机挖掘判决的错误率增加 0.0319。所以综合权衡计算资源分配与算法效率,本文采用原始 MFCC 静态系数作为分类模型的输入特征。

3.5.5 对高斯模型数量的分析

混合高斯模型的成分数量的选择影响事件特征建模性能,每个 GMM 对应特征空间中的一个概率密度分布中心,其混合阶数本质上决定了模型对特征空间划分的精细程度。当混合阶数设置过低时,模型对特征空间的覆盖能力不足,导致声学特征中的细节信息被过度平滑,这种表征缺陷在识别过程中表现为模式混淆现象,造成分类精度下降。而混合阶数过高时,同样带来维度和识别问题,参数估计过程将陷入过拟合状态,不仅导致计算资源消耗的增长,更使特征空间被过度分割,造成背景噪声与有效信号的误判概率上升。

混合数量不足将削弱模型的特征表征能力,导致识别率降低;混合阶数过高则会引发计算资源增加与识别误判,需通过实验确定最优参数平衡识别精度与计算效率。目前未有理论方法能够准确估计最优高斯模型数量,但模型拟合效果直观反映在等错误率指标中,通过等错误率曲线的变化趋势可直观评估不同模型数量下模型的拟合效果。当混合数量达到某一临界阈值时,等错误率指标由下降转为上升,此转折点即为模型从欠拟合向过拟合状态转换的临界区域,可作为模型数量的最

优参数。图 3-16 为 GMM-UBM 模型不同高斯模型数对应的等错率曲线。随着高斯混合模型中高斯成分数量的递增，当混合阶数未超过 12 时，油夯机施工与挖机挖掘的等错误率波动较小，而人工挖掘事件的 EER 有较明显的增加，但总体错误率仍保持下降趋势，并于混合阶数为 12 时达到全局最小值；当混合阶数增至 14 时，由于油夯机施工事件的等错误率的陡增，导致总错误率出现峰值 0.3460，此后，总错误率略有回落，但仍高于模型数为 12 时的最优水平；后续变化趋势开始变得相对平缓，这表明进一步增加模型数量对于降低错误率已经非常有限。




图 3-16 GMM-UBM 模型高斯模型数-等错误率关系图

综合以上分析，在当前的应用场景和数据集下，选择 12 个混合高斯模型作为最优配置，能够在保证识别性能的同时，也避免了因模型数量过多而导致的计算复杂度和资源消耗的增加。

3.5.6 模型识别效果和对单阈值识别的分析

在确定 MFCC 静态特征，排除动态差分参数、设置 16 通道梅尔滤波器组及 12 成分高斯混合模型的基础上，实验首先采用训练集完成 GMM-UBM 模型训练，并通过测试集计算 EER 指标，同时，使用相同的训练集和测试集，对比使用单阈值和多阈值判决的 EER 和识别率。

通过绘制接收者操作特征（Receiver Operating Characteristic Curve, ROC）曲线直观呈现 FAR 与 FRR 的关系，ROC 是一种评价分类模型的可视化工具，其与

原点参考线的交点即为 EER，图 3-17 展示了根据 FAR 和 FRR 绘制单阈值和多阈值判决的 ROC 曲线。曲线越接近原点方向，表明模型性能趋近于理想状态，FAR 和 FRR 达到平衡地最低，图 (b) 中三类事件的曲线较接近原点，人工挖掘事件的 EER 为 0.0342，挖机挖掘事件为 0.0315，油夯机施工事件为 0.0708；图 (a) 中，曲线明显偏离原点，三类时间的平均 EER 为 0.2565。通过比较可知，单阈值的 EER 值高于多阈值中任一类事件的 EER。




图 3-17 ROC 曲线。(a) 单阈值；(b) 多阈值

进一步地，为验证单阈值判决模型存在拒绝率高的问题，同时测试改进后的识别率，再使用相同验证集数据分别对训练完成的 GMM-UBM 模型进行单阈值、多阈值的分类识别测试，识别的混淆矩阵如图 3-18：




图 3-18 GMM-UBM 模型识别混淆矩阵。(a) 单阈值判决；(b) 多阈值判决

图(b)中验证集的平均识别率为 0.9751, 其中非目标事件信号识别率为 0.9784, 少数非目标事件信号被识别为油夯机施工信号; 人工挖掘信号的识别率较其他三类低, 为 0.9545, 部分数据被识别为非目标事件信号和挖机信号; 挖机挖掘信号识别率最高, 为 0.9929, 只有极少数被误判为人工挖掘信号; 油夯机施工信号识别率为 0.9702, 少数被识别为非目标事件和挖机挖掘信号。

和图 (b) 多阈值的非目标事件、挖机挖掘、油夯机施工的识别率判决对比, 图 (a) 中单阈值判决模型差距较小, 而单阈值对于人工挖掘事件的识别率影响较大, 有明显更多的事件被判决为非目标事件, 拒绝率增加了 18.22%, 三类事件寻优过程确定的阈值如表 3-4。

表 3-4 三类事件寻优阈值

事件类型	阈值
人工挖掘	0.9445
挖机挖掘	2.8964
油夯机施工	1.9063

人工挖掘的阈值在三类事件中最低, 由此可以验证单阈值判定存在增加多类事件中低阈值事件的拒绝率问题。

最后, 为验证 GMM-UBM 模型的识别性能和计算复杂度, 本文记录了模型对 500 个通道信号的识别时间和模型占用内存大小, 参数指标如表 3-5。

表 3-5 识别参数指标

参数	指标
500 通道识别时间(ms)	8.31
模型大小(KB)	22.2

GMM-UBM 模型对于 500 个通道各输入 3s 语音特征的识别时间为 8.31 ms, 且模型占用内存仅 22.2KB, 说明其计算的复杂度较低, 是一种轻量化的模型。结合其识别时间短、模型较小的优势, 能够满足实际系统对入侵事件的监测的实时性要求。

3.6 本章小结

本章首先对声纹识别系统的特征提取方法及识别模型进行了介绍, 特征提取是实现声纹识别的关键环节, 详细分析了线性预测系数 LPC、线性预测倒谱系数

LPCC 及梅尔频率倒谱系数 MFCC 三种方法的特点, 根据三类管道事件信号的时域频域分布特征, 分析了三种特征提取方法的适用性, 选择了 MFCC 作为声纹特征的提取参数。接着, 介绍了声纹识别的训练和识别流程, 包括高斯混合模型-通用背景模型 GMM-UBM 结构、优化模型参数 EM 算法, K-means 初始化算法、调整目标事件模型参数的 MAP 自适应算法, 识别流程包括结合特征向量、背景模型、目标模型打分的 LLR 算法、阈值判决。最后, 通过对三类管道入侵事件的识别实验研究了梅尔滤波器数量、MFCC 动态参数、混合高斯模型数量对识别率的影响, 确定梅尔滤波器数量为 16、高斯模型数为 12, 不引入动态参数, 并评估了 GMM-UBM 模型在识别率、识别速度及模型复杂度方面的性能, 同时验证了单阈值判决模型存在增加拒绝率的问题。实验结果表明, GMM-UBM 模型能够在保持较高识别率的同时, 满足系统对入侵事件监测对实时性和计算效率的需求。

第四章 管道入侵事件声纹识别系统设计与算法实现

第二章已对管道入侵事件监测系统的结构、 Φ -OTDR 技术探测振动信号的基本原理和信号的解调原理进行分析, 本文将基于以上理论设计管道入侵事件声纹识别系统, 同时结合第三章识别时延指标和提取静态特征参数结论, 本文提出基于 FPGA 片上采集-解调-特征提取、上位机识别方案, 仅针对梅尔倒谱特征提取算法设计加速, 在 3s 内完成对多通道同时传输的 3s 解调后的音频信号的特征提取。

4.1 系统结构

FPGA 端作为主控芯片完成信号的采集、解调、特征提取, 上位机接收解调信号和特征参数, 其中特征参数经过推理识别输出识别结果, 与解调信号同步传输至可视化界面显示。基于 FPGA 的管道入侵事件的声纹识别系统的算法设计如图 4-1, 识别系统分为四个部分: 信号采集、信号处理、数据传输、识别显示。信号采集和信号处理的解调模块包含入侵事件监测系统现有的信号探测、AD 采集、解调方法。通过 AD9643 采集后向瑞利散射信号, 并将传输至 FPGA 的各个通道数据进行实时解调, 实现了从外部的模拟信号到高保真数字信号的转化。




图 4-1 声纹识别系统算法结构

信号处理的特征提取模块实现解调后的振动信号的 MFCC 特征提取, 输出端并行输出梅尔倒谱系数; 数据传输部分包含 FPGA 传输系数的并串转换、PS 端的 ARM 处理器的内存映射、特征信号与解调信号传输, 以及从上位机发出的控制指令传回到 FPGA; 识别显示部分在上位机完成, 包括部署 GMM-UBM 模型推理识别、界面显示事件信息。

在 FPGA 端还需完成各通道解调信号的 MFCC 特征提取、特征数据适应 AXI 数据格式的 Concat 并串转换和基于 AXI_FIFO、AXI_DMA 的特征数据映射。ARM 端还需执行同步时钟驱动、基于 TCP/IP 协议实现特征数据和解调信号的封装传输、通过 AXI-Interconnect 和 AXI-GPIO 将上位机控制指令传输到 FPGA 端的脉冲触发-采集控制模块。上位机实现功能包括接收数据、调用 GMM-UBM 模型参数执行事件类型判别、可视化界面动态显示事件识别结果等信息、通过 TCP/IP 协议向 ARM 端下发采集控制指令。

4.2 同步时钟驱动及探测参数设置

ZYNQ IP 核中生成 100MHz 时钟作为全局同步时钟, 为 AD 采集模块提供 ADC 的数据采集时钟, 同时, 生成 10MHz 作为信号处理部分中解卷绕和特征提取模块的同步时钟信号, 时钟频率的设定基于系统解调空间分辨率指标: DAS 系统探测空间分辨率为 1m, 解调的空间分辨率为 10m, 将解调同步时钟频率降频至全局时钟的十分之一, 确保全系统数据处理流程的时序一致。

在确定全局同步时钟后, 可推导光脉冲触发-采集模块参数。系统采用 1kHz 重复频率的脉冲光探测模式, 探测通道数量为 N_{sample} 段, 由 2.5 节理论计算 N_{total} 为 100000; 光脉冲宽度为 100ns, 对应 N_{pwm} 为 10; 系统理论最大探测距离为 100km, 根据实际探测通道数量需求设置 $N_{trigger}$, 当通道数为 500 时, $N_{trigger}$ 为 5000。

4.3 特征提取部分设计

图 3-4 展示了 MFCC 提取算法计算流程, 在 FPGA 端设计中, 将该流程划分为预处理、梅尔倒谱系数计算两大功能模块, 以下详细分析两模块算法设计思路并介绍实现流程。

4.3.1 预处理模块

预处理流程主要包括单通道数据累积、分帧和加窗三个步骤。系统采用串行模式传输多通道数据, 而特征提取处理需基于单通道分帧后的帧数据, 因此需在分帧前完成单通道数据的累积操作。其次, 分帧过程采用帧移为帧长一半的重叠分帧策

略,即相邻帧之间将存在 50%的重叠区域。这种重叠结构在串行数据流中表现为:除首尾两个半帧外,中间段的半帧数据均重复传输一次。在重复传输过程中,为确保特征提取输入端解调数据的完整性,分帧过程设计基于有限状态机(Finite State Machine, FSM)控制的同步时钟双缓存结构。模块设计分为以下步骤:

(1) 单通道数据累积

本设计采用基于真双端口存储器(True Dual-port RAM)的乒乓缓冲操作实现数据流实时处理,乒乓操作使用两个独立的数据缓冲区,通过交替使用这两个缓冲区实现数据的连续处理乒乓操作:当一个缓冲区用于读取数据时,另一个缓冲区同时用于写入新数据,待缓冲区写满或读空后立即切换读写状态。

本文在一个 RAM 中开辟两个写周期写入的深度的缓冲区,采集通道数为 N_{sample} ,在每个写周期内,写入 N_{sample} 个通道各半帧长度数据,每帧数据长度为 32。计算每个写周期写入深度 DEPTH_CYCLE 为 $16 * N_{sample}$,RAM 的深度设为 $2 * DEPTH_CYCLE$ 。读写地址位宽 WIDTH_ADDR 使用系统的位宽计算函数 $\$clog2$ 根据 RAM 深度匹配。为实现每个通道的半帧数据在 RAM 中的连续存储,写地址采用跨步寻址,通过固定每个写周期的地址偏移量来写指定地址的数据,确保写入半帧数据按通道顺序排列。跨步寻址设计结构及读写示意图如图 4-2。在跨步寻址电路中,wr_addr 是写地址,在每个写周期内,每个时钟上升沿以固定步长 16 递增;cnt 是通道计数器,用于计当前写入数据的通道序号;wr_start_addr 寄存器存储下一次输入的一个通道数据的首个数据写起始地址,预置值为 1,当 cnt 计满时,wr_start_addr 赋值 wr_addr 并加 1。




图 4-2 跨步寻址电路及读写示意图

读写示意图中展示了在第一个写周期中写操作跨步寻址路径和第一个读周期中行读地址顺序。wr_cycle 和 rd_cycle 分别表示读、写周期, cycle1~3 为在时间顺序下的周期节点;RAM 存储的 chani_j 表示第 i 个通道第 j 个数据,为方便表示,

图中总通道数写为 N 。在读写过程的 cycle1 周期内, 执行第一个周期的写操作寻址路径为 $\text{chan1}_0, \text{chan2}_0, \dots, \text{chanN}_0, \text{chan1}_1, \text{chan2}_1, \dots, \text{chanN}_1, \dots, \text{chanN}_{15}$ 。当累积满 DEPTH_CYCLE 个通道的半帧数据时, 进入 cycle2 周期, 开始向下一 DEPTH_CYCLE 深度的缓冲区按照与 cycle1 中相同的寻址方式写入新数据, 同时执行第一个周期的读操作, 从 RAM 中按地址升序依次读取 RAM 中存储的数据。当第二个写周期完成时, 第一个读周期同步结束, 进入 cycle3 开始第二个 DEPTH_CYCLE 个通道半帧数据的读周期。至此, 完成一个周期读写乒乓操作。

(2) 状态机控制读写操作的双 FIFO 分帧结构

在双 FIFO 结构中分为: 主 FIFO 和中转缓冲 FIFO。两个 FIFO IP 核均配置为 Common Clock Block RAM, 深度为 DEPTH_CYCLE 。主 FIFO 负责接收从 RAM 读取的半帧累积数据; 中转缓冲 FIFO 用于暂存主 FIFO 输出的半帧数据流。分帧结构的双 FIFO 端口连接方式为: 数据输入端直连至主 FIFO 的 din 端口, 其写使能信号 wr_en 在全过程中保持置位状态, 中转缓冲 FIFO 的 din 端口与主 FIFO 的 dout 端口直连。针对分帧过程实现的状态机如图 4-3, 分帧状态机由三个主要状态构成: IDLE 、 $\text{RD_FIRST_HALFFRAME}$ 和 RD_NEXT_HALFFRAME 。两个 FIFO 中, 主 FIFO 命名为 $\text{FIFO_NEXT_HALFFRAME}$, 中转缓冲 FIFO 命名为 $\text{FIFO_FIRST_HALFFRAME}$ 。




图 4-3 状态机分帧逻辑示意图

在 IDLE 状态下, 执行系统初始化操作, 向 $\text{FIFO_FIRST_HALFFRAME}$ 与 $\text{FIFO_NEXT_HALFFRAME}$ 分别写入首帧的前半帧与后半帧数据, 当双 FIFO 写满时状态移向 $\text{RD_FIRST_HALFFRAME}$, 若未写满则维持 IDLE 状态; 在 $\text{RD_FIRST_HALFFRAME}$ 状态下, 开始读取 $\text{FIFO_FIRST_HALFFRAME}$ 中缓存的

前半帧数据，当读空时状态机移向 RD_NEXT_HALFFRAME 状态，否则保持读帧状态；在 RD_NEXT_HALFFRAME 状态下，开始读取 FIFO_NEXT_HALFFRAME 中缓存的后半帧数据，同时将输出数据回写至 FIFO_FIRST_HALFFRAME 中，若完成半帧读取且 FIFO 未读空，则返回 RD_FIRST_HALFFRAME 状态以处理下一重叠帧，读下一帧数据中与前一帧重叠的前半帧，如果 FIFO 读空，则移向 IDLE 状态，否则状态机保持本状态。

(3) 加汉宁窗

分帧后的单帧数据通过 32 点汉宁窗函数进行加窗处理，该模块通过一个单端口 ROM (Single Port ROM) 和一个乘法器实现，将预先计算的定点化汉宁窗系数存储于 ROM 中，通过地址计数器按帧同步读取窗系数，同时，帧数据输入至乘法器另一侧，窗系数与帧数据经定点乘法器执行逐点乘运算，输出加窗后的时域帧数据。

基于以上分析，预处理实现结构如图 4-4。




图 4-4 预处理实现结构

4.3.2 梅尔倒谱系数计算模块

倒谱系数计算过程包含傅里叶变换的频谱能量计算、梅尔滤波对数化及离散余弦变换三个阶段。其模块设计与实现如下：

(1) 频谱能量计算

快速傅里叶变换过程使用一个快速傅里叶变换 IP (Fast Fourier Transform IP) 实现。FFT IP 的参数配置为：流水线 Pipelined 结构、输出截位方式为 Unscaled、排序选择自然排序 Natural Order，同时虚部输入端口固定置零且位宽与实部对齐。频谱能量计算通过模平方运算实现，采用两个乘法器分别计算实部与虚部分量平方值，再经加法器输出模平方结果。

(2) 梅尔滤波器组滤波

梅尔滤波器设计需构建 16 组三角滤波器，如图 3-5 (b)，其频带按梅尔刻度非均匀分布，每个滤波器都具有不同的梅尔频率范围。梅尔滤波过程就是计算帧信号在每个滤波器频域内的能量的过程，即每个滤波器通过频点加权求和计算对应频段的能量值，因此设计帧能量分别和滤波器系数作相乘求和运算。

图 4-5 为每个滤波器系数的分布情况。滤波器组中，除首尾滤波器外，各滤波器的高、低截止频率分别与相邻滤波器中心频率对齐，截止频率对应幅值为零，在此重叠频段的频率点均需乘两个系数。而首滤波器低于中心频段、末滤波器高于中心频段为非重叠频段，在此频段内的频率点只需乘一个滤波器系数。




图 4-5 梅尔滤波器系数分布

本文设计采用双 ROM 定点存储滤波器系数，两个 ROM 分别存储各频率点对应的两个滤波器中前序和后续的滤波器系数，深度均为 16。滤波系数加权计算结构如图 4-6。




图 4-6 梅尔滤波计算结构

梅尔滤波器组滤波计算通过计数器实现过程控制：设置一个计数器统计已处理的频点数，控制输出有效信号 `valid`，其计数周期设置为滤波器重叠总长度 17。当输入每帧的第一个能量点时，第一个滤波器仍有系数没有计算，此时输出有效信号置零；自第二个能量点输入起，输出有效信号持续置位。

输入一个采样点的能量时同步触发 ROM 系数读取操作, 同时 cnt 开始计数, 接着, 将输入能量拆分为两路并行处理: 分别通过乘法器计算系数和能量的乘积 mul_row1 和 mul_row2, 采用两个寄存器实现跨周期数据传递, temp_row2 寄存当前 mul_row2 值, sum_row1_row2 计算当前 mul_row1 与前一周期 mul_row2 之和, 作为当前滤波器输出。最后, 在每个时钟周期上升沿触发 sum_row1_row2 寄存器更新, 并输出滤波器频段能量值。

滤波后的系数经过以 10 为底的对数运算以计算倒谱系数。由于离散余弦变换阶段将对系数进行归一化处理, 根据对数换底公式, 底数选择不影响最终归一化结果, 所以本文利用浮点运算 IP 核(Floating-point IP)中的对数计算模块(Logarithm)直接计算自然对数。

综上, 频谱能量计算模块与梅尔滤波器组的实现结构如图 4-7, 对每输入的一帧信号进行首先经过频谱能量计算模块, 随后通过梅尔滤波器组模块进行频域滤波处理, 最终, 每个倒谱系数通过一个寄存器以并行方式输出 16 个倒谱值, 用于后续的离散余弦变换处理。




图 4-7 梅尔滤波实现结构

(3) 离散余弦变换

离散余弦变换模块依据式 3-13 实现, 其计算过程通过不同频率余弦基函数与对数梅尔倒谱系数的互相关运算完成。该运算可展开为如式 4-1 所示的矩阵乘法形式。

$$C(k) = \begin{bmatrix} \frac{1}{4} & \cdots & \frac{1}{4} & \frac{1}{4} & \cdots & \frac{1}{4} \\ \sqrt{\frac{1}{8}} \cos(\frac{\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{15\pi}{32}) & \sqrt{\frac{1}{8}} \cos(\frac{17\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{31\pi}{32}) \\ \sqrt{\frac{1}{8}} \cos(\frac{2\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{30\pi}{32}) & \sqrt{\frac{1}{8}} \cos(\frac{34\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{31\pi}{32}) \\ \sqrt{\frac{1}{8}} \cos(\frac{3\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{45\pi}{32}) & \sqrt{\frac{1}{8}} \cos(\frac{51\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{62\pi}{32}) \\ \sqrt{\frac{1}{8}} \cos(\frac{4\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{60\pi}{32}) & \sqrt{\frac{1}{8}} \cos(\frac{68\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{2\pi}{32}) \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ \sqrt{\frac{1}{8}} \cos(\frac{15\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{225\pi}{32}) & \sqrt{\frac{1}{8}} \cos(\frac{255\pi}{32}) & \cdots & \sqrt{\frac{1}{8}} \cos(\frac{465\pi}{32}) \end{bmatrix} \begin{bmatrix} L(0) \\ L(1) \\ \cdots \\ L(N-1) \end{bmatrix} \quad (4-1)$$

若直接全矩阵遍历计算,需频繁执行浮点乘法操作,导致乘法器资源消耗剧增。为减少乘法资源的消耗,并在矩阵系数较多时其类型适合 FPGA 进行数据处理,本文采用高效视频编码(High Efficiency Video Coding, HEVC)标准^[61]中一种的整数 DCT 变换矩阵实现快速变换,同时结合基于行列分离的 8 点 DCT 变换快速算法的计算形式^[62],将浮点变换矩阵的系数近似为整数,HEVC 标准整数矩阵如式 4-2:

$$C(k) = \frac{1}{256} \cdot \begin{bmatrix} 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 & 64 \\ 90 & 87 & 80 & 70 & 57 & 43 & 25 & 9 & -9 & -25 & -43 & -57 & -70 & -80 & -87 & -90 \\ 89 & 75 & 50 & 18 & -18 & -50 & -75 & -89 & -89 & -75 & -50 & -18 & 18 & 50 & 75 & 89 \\ 87 & 57 & 9 & -43 & -80 & -90 & -70 & -25 & 25 & 70 & 90 & 80 & 43 & -9 & -57 & -87 \\ 83 & 36 & -36 & -83 & -83 & -36 & 36 & 83 & 83 & 36 & -36 & -83 & -83 & -36 & 36 & 83 \\ 80 & 9 & -70 & -87 & -25 & 57 & 90 & 43 & -43 & -90 & -57 & 25 & 87 & 70 & -9 & 80 \\ 75 & -18 & -89 & -50 & 50 & 89 & 18 & -75 & -75 & 18 & 89 & 50 & -50 & -89 & -18 & 75 \\ 70 & -43 & -87 & 9 & 90 & 25 & -80 & -57 & 57 & 80 & -25 & -90 & -9 & 87 & 43 & -70 \\ 64 & -64 & -64 & 64 & 64 & -64 & -64 & 64 & 64 & -64 & -64 & 64 & 64 & -64 & -64 & 64 \\ 57 & -80 & -25 & 90 & -9 & -87 & 43 & 70 & -70 & -43 & 87 & 9 & -90 & 25 & 80 & -57 \\ 50 & -89 & 18 & 75 & -75 & -18 & 89 & -50 & -50 & 89 & -18 & -75 & 75 & 18 & -89 & 50 \\ 43 & -90 & 57 & 25 & -87 & 70 & 9 & -80 & 80 & -9 & -70 & 87 & -25 & -57 & 90 & -43 \\ 36 & -83 & 83 & -36 & -36 & 83 & -83 & 36 & 36 & -83 & 83 & -36 & -36 & 83 & -83 & 36 \\ 25 & -70 & 90 & -80 & 43 & 9 & -57 & 87 & -87 & 57 & -9 & -43 & 80 & -90 & 70 & -25 \\ 18 & -50 & 75 & -89 & 89 & -75 & 50 & -18 & -18 & 50 & -75 & 89 & -89 & 75 & -50 & 18 \\ 9 & -25 & 43 & -57 & 70 & -80 & 87 & -90 & 90 & -87 & 80 & -70 & 57 & -43 & 25 & -9 \end{bmatrix} \begin{bmatrix} L(0) \\ L(1) \\ \dots \\ L(N-1) \end{bmatrix} \quad (4-2)$$

将矩阵中的系数归纳为表 4-1:

表 4-1 HEVC 标准整数矩阵系数

H_0	90	H_1	87	H_2	80	H_3	70	H_4	57
H_5	43	H_6	25	H_7	9	H_8	89	H_9	75
H_{10}	50	H_{11}	18	H_{12}	64	H_{13}	83	H_{14}	36

HEVC 标准中使用的整数 DCT 变换通过将浮点 DCT 变换矩阵中的元素近似为整数来实现的,这种方法在消除浮点运算减少了硬件实现的复杂度的同时,通过优化系数缩放因子使量化误差最小化,兼顾硬件实现效率与计算精度。

变换系数分布中具有如式 4-3 的对称规律:

$$H(k, m) = \begin{cases} H(k, N-1-m) & k = 0, 2, \dots, N-2 \quad m = 0, 1, \dots, \frac{M}{2}-1 \\ -H(k, N-1-m) & k = 1, 3, \dots, N-1 \quad m = 0, 1, \dots, \frac{M}{2}-1 \end{cases} \quad (4-3)$$

其中 k 为频率系数, m 为采样点位置。在不同频率的余弦函数中,当 k 为奇数时,点位为 m 的系数均与 $N-1-m$ 位置的系数相反; k 为偶数时,点位为 m 的系数均与 $N-1-m$ 位置的系数相等。基于以上对称规律,可通过对称点位的倒谱系数对构建中间变量,表示为式 4-4 形式:

$$\begin{cases} x(0) = L(0) + L(15), x(1) = L(1) + L(14) \\ x(2) = L(2) + L(13), x(3) = L(3) + L(12) \\ x(4) = L(4) + L(11), x(5) = L(5) + L(10) \\ x(6) = L(6) + L(9), x(7) = L(7) + L(8) \\ y(0) = L(0) - L(15), y(1) = L(1) - L(14) \\ y(2) = L(2) - L(13), y(3) = L(3) - L(12) \\ y(4) = L(4) - L(11), y(5) = L(5) - L(10) \\ y(6) = L(6) - L(9), y(7) = L(7) - L(8) \end{cases} \tag{4-4}$$

将这种表示设计为输入加法器单元，如图 4-8 所示。加法器单元由 8 个蝶形运算单元构成，每个单元独立计算两个中间值 $x(n)$ 和 $y(n)$ ， $n=1,2,...,7$ 。每个蝶形运算模块采用加减法组合逻辑结构，完成对输入数据同步加减运算。




图 4-8 输入加法器单元结构

接着，对于 $x(n)$ 和 $y(n)$ 的计算划分为以下两步骤：

（1）中间乘法器、输出加法数单元。在式 4-4 中 $y(n)$ 的系数不存在进一步的对称关系，直接将每个 $y(n)$ 与整数系数 $H_0 \sim H_7$ 相乘，共做 64 次乘法，然而，传统浮点乘法器资源消耗高、时序复杂，本文设计多路并行移位器作为中间乘法器单元，通过并行化移位操作提升乘法运算的效率，并降低组合逻辑资源 LUT 的消耗。移位操作配置如表 4-2，对于不同的系数乘法分别使用移位叠加的方法实现，且为避免减法导致的符号位扩展问题，移位配置优先使用加法。

表 4-2 16 点 DCT 中间乘法器单元的移位-加法分解

目标乘式	移位-加法分解
90*y	(y<<<6)+(y<<<4)+(y<<<3)+(y<<<1)
87*y	(y<<<6)+(y<<<4)+(y<<<2)+(y<<<1)+y
80*y	(y<<<6)+(y<<<4)
70*y	(y<<<6)+(y<<<2)+(y<<<1)
57*y	(y<<<5)+(y<<<4)+(y<<<3)+y
43*y	(y<<<5)+(y<<<3)+(y<<<1)+y
25*y	(y<<<4)+(y<<<3)+y
9*y	(y<<<3)+y

在计算乘系数后，对每个单元输出的结果根据式 4-2 的系数正负作加法运算，输出加法树结构如图 4-9。




图 4-9 三级加法数计算结构

其中， $y_h(n)$ 表示 $y(n)$ 和对应矩阵系数 H 的乘积。为避免单级计算过长造成的资源浪费和关键路径延迟增加，将长加法链拆分为三级加法树，实现层级拆分：每个加法树计算一个乘法单元的 8 路数据，第一级加法树对输入的 8 路数据进行初步累加，生成中间结果；第二级加法树进一步对中间结果进行整合；最后，第三级加法树完成最终的累加操作，输出一个 $C(n)$ 。

(2) 8 点-4 点 DCT 变换结构。在式 4-4 中 $x(n)$ 的系数对称关系如式 4-5，点位为 m 的系数与 $N/2-1-m$ 处的系数呈现等值或反相的关系。

$$H(k, m) = \begin{cases} H(k, \frac{N}{2}-1-m) & k=0, 4, \dots, N-4 \quad m=0, 1, \dots, \frac{M}{4}-1 \\ -H(k, \frac{N}{2}-1-m) & k=2, 6, \dots, N-2 \quad m=1, 3, \dots, \frac{M}{4}-1 \end{cases} \quad (4-5)$$

基于上述对称关系，在倒谱系数与变换矩阵的偶数行相乘运算中，使用 $x(n)$ 写为式 4-6 形式：

$$\begin{cases} C(0) = H_8[x(0) + x(7)] + H_8[x(1) + x(6)] + H_8[x(2) + x(5)] + H_8[x(3) + x(4)] \\ C(2) = H_9[x(0) - x(7)] + H_{10}[x(1) - x(6)] + H_{11}[x(2) - x(5)] + H_{12}[x(3) - x(4)] \\ C(4) = H_{13}[x(0) + x(7)] + H_{14}[x(1) + x(6)] - H_{14}[x(2) + x(5)] - H_{13}[x(3) + x(4)] \\ C(6) = H_{10}[x(0) - x(7)] - H_{12}[x(1) - x(6)] - H_9[x(2) + x(5)] - H_{11}[x(3) - x(4)] \\ C(8) = H_8[x(0) + x(7)] - H_8[x(1) + x(6)] - H_8[x(2) + x(5)] + H_8[x(3) + x(4)] \\ C(10) = H_{11}[x(0) - x(7)] - H_9[x(1) - x(6)] + H_{12}[x(2) + x(5)] + H_{10}[x(3) - x(4)] \\ C(12) = H_{14}[x(0) + x(7)] - H_{13}[x(1) + x(6)] + H_{13}[x(2) + x(5)] - H_{14}[x(3) + x(4)] \\ C(14) = H_{12}[x(0) - x(7)] - H_{11}[x(1) - x(6)] + H_{10}[x(2) + x(5)] - H_9[x(3) - x(4)] \end{cases} \quad (4-6)$$

此时计算形式为类似 16 点的 8 点 DCT 变换，其对称性与 16 点 DCT 变换的分析结论一致，此处设计和 16 点 DCT 结构基本一致的 8 点 DCT 变换单元。具体实现存在以下差异：输入加法器单元蝶形计算结构缩减为 4 个，输入加法器单元结构如图 4-10 (a)，其中， $b_h(n)$ 表示 $b(n)$ 和对应矩阵系数 H 的乘积；中间乘法器

单元系数数量为 4 个，系数为的 $H_8 \sim H_{11}$ ，中间乘法器单元的移位配置如表 4-3；输出加法树单元加法结构为 2 级，输出二级加法树单元结构如图 4-10（b）。




图 4-10 8 点 DCT 变换结构。（a）输入加法器单元结构；（b）输出二级加法树单元结构

表 4-3 8 点 DCT 中间乘法器单元的移位-加法分解

目标乘式	移位-加法分解
$89*y$	$(y<<<6)+(y<<<4)+(y<<<3)+y$
$75*y$	$(y<<<6)+(y<<<3)+(y<<<1)+y$
$50*y$	$(y<<<5)+(y<<<4)+(y<<<1)$
$18*y$	$(y<<<4)+(y<<<1)$

在此基础上，8 点 DCT 变换的输入加法器单元计算结果的偶数行 $a(n)$ 可以进一步使用 4 点 DCT 变换计算，这是 DCT 变换的最小单元，4 点 DCT 结构的输入加法器单元蝶形结构为 2 个，输入加法器单元结构如图 4-11（a）。中间乘法器单元系数数量为 3 个，变换系数为的 $H_{11} \sim H_{13}$ ，中间乘法器单元的移位配置如表 4-4， $s_h(n)$ 和 $t_h(n)$ 分别表示 $s(n)$ 和 $t(n)$ 与对应矩阵系数 H 的乘积。输出加法树单元加法结构为 2 级，输出一级加法树单元结构如图 4-11（b）。

表 4-4 4 点 DCT 中间乘法器单元的移位-加法分解

目标乘式	移位-加法分解
$64*a$	$a<<<6$
$83*a$	$(a<<<6)+(a<<<4)+(a<<<1)+a$
$36*a$	$(a<<<5)+(a<<<2)$




图 4-11 4 点 DCT 变换结构。(a) 输入加法器单元结构；(b) 输出一级加法树单元结构

基于以上分析，本文设计的 16 点 DCT 的蝶形算法 (Butterfly Algorithm) 计算结构如图 4-12。结构的核心思想是对称路径共享加法器资源与系数合并优化，首先，在输入加法器单元通过合并计算具有相同或相反系数的倒谱项，以加减法运算代替部分乘法生成中间值 $x(n)$ 和 $y(n)$ 。接着，中间值被传递至下一级的 8 点 DCT 结构和中间乘法器单元，8 点 DCT 结构中具有相同或相反系数的项进一步合并；中间乘法器乘标准化整数系数，最后输出加法器单元通过两级加法树输出变换系数。




图 4-12 16 点 DCT 蝶形算法计算结构

为提升算法计算效率与资源利用率，本文设计七级流水线式结构来运行 DCT 算法实现高吞吐、低延迟的实时信号处理。流水线设计是平衡吞吐量、时序收敛与资源消耗的关键策略，尤其在处理高复杂度、高吞吐量需求的算法时效果显著。七

级流水线式结构将 DCT 每个单元的计算分解为独立的逻辑阶段，并插入寄存器分割关键路径，通过复用模块减少资源冗余。流水结构如图 4-13，七级划分为：pipe0 执行输入加法器单元，使用二级寄存器逐级寄存计算结果；pipe1 执行 8 点 DCT 结构的输入加法器单元，通过一级寄存器保存中间结果；pipe2 执行 8 点 DCT 结构下的 4 点输入加法器单元；pipe3 提取 pipe0~pipe2 的最高级寄存器值，执行 16 点、8 点、4 点变换的中间乘法器单元；pipe4~pipe6 执行三级加法树单元。




图 4-13 DCT 七级流水计算结构

变换后的系数再做归一化计算，归一化是除系数最大值的过程，因为 DCT 变换已经将能量集中在低频部分，由先验信息已知最大值分布在 $C(0)$ 和 $C(1)$ ，且 $C(1)$ 为负值，此时仅比较 $C(0)$ 和 $-C(1)$ ，较大值作为除数输入除法器实现系数归一化，得到最终的梅尔倒谱系数。

4.4 数据传输部分设计

在完成特征参数的提取后，需将参数传输至上位机以进行后续识别与显示，数据传输部分将完成数据上传路径为 FPGA-ARM-上位机的参数传输，此外，信号采集解调部分的探测和采集触发由上位机控制，数据传输部分还需要完成控制下发路径即上位机-ARM-FPGA 的触发控制指令传输。

在数据上传路径中，首先将特征参数转换为 AXI 格式，接着通过 AXI-DMA 数据传输通道将参数映射至 ARM 端的 DDR 内存中，最后 ARM 端通过 TCP/IP 协议传输数据至上位机；在控制下发路径中，从上位机同样通过 TCP/IP 控制命令传回 ARM 端，使用 AXI-GPIO 向 FPGA 传回控制数据。

4.4.1 数据上传设计

上传数据为每帧信号的特征参数和解调后的信号。每个特征参数的位宽为 32bit，针对这种传输大量数据的情况，系统中采用的是 AXI4^[63-64]总线传输方式，并选择 AXI4-Stream 模式，这种模式提供连续数据流的高速传输，适合本文中大量特征参数的实时传输需求。

为了与 AXI4 接口兼容，需要将数据的 Native 接口类型转换为 AXI 类型，AXI4-Stream 模式规定了主从接口需遵循握手协议，接口含有流控制信号 TVALID、TREADY、TLAST 和数据信号 TDATA，其中，TDATA 类型为字节流格式。使用 Concat IP 实现数据的格式转换，将并行传输的 12 个 32bit 特征参数拼接，并高位补 0 扩展位宽，输出 512bit 串行数据流。

AXI 支持的数据传输机制主要有两种：单笔传输（Single Transfer）和多笔传输（Burst Transfer）。单笔传输每次传输仅包含一个数据项；多笔传输一次传输一帧数据，一帧包含多个连续的数据项。本文设计将拼接后的 512bit 串行数据流输入异步 AXI-FIFO^[65]，异步 FIFO 的写时钟为 10MHz，读时钟为 100MHz，深度为 4096，保证 FIFO 有足够的深度进行数据缓存，数据传输采用多笔传输机制进行数据帧的传输，每一帧包括 N_{sample} 个通道各 512bit 数据项。在跨时钟域下，和从接口遵循握手协议实现数据传输。

在数据接口转换为 AXI 后，将数据传输至 ARM 核的 DDR 中，使用 AXI-DMA 在 ARM 核的 DDR 中为无地址映射的 AXI4-Stream 流式数据开辟映射空间，使 Stream 数据兼容 ARM 内存，数据先进入 AXI-DMA^[66]，接着从 AXI-DMA 直接到达 DDR 的映射地址。AXI-DMA IP 配置如图 4-14。

The image shows the AXI-DMA IP configuration interface. It includes several checkboxes for enabling features like Asynchronous Clocks, Scatter Gather Engine, Micro DMA, Multi Channel Support, and Control / Status Stream. Below these are input fields for 'Width of Buffer Length Register (8-26)' set to 23 bits and 'Address Width (32-64)' set to 32 bits. The interface is divided into two main sections: 'Enable Read Channel' and 'Enable Write Channel'. The 'Read Channel' section has settings for Number of Channels (1), Memory Map Data Width (32), Stream Data Width (32), and Max Burst Size (16). The 'Write Channel' section has settings for Number of Channels (1), Memory Map Data Width (512), Stream Data Width (512), and Max Burst Size (64). There are also checkboxes for 'Allow Unaligned Transfers' and 'Use Rlength in Status Stream'. At the bottom, there is a checkbox for 'Enable Single AXI4 Data Interface'.

图 4-14 AXI-DMA IP 配置

4.4.2 控制下发设计

上位机的控制指令包括触发光脉冲探测和 AD 采集、特征参数输入 AXI 总线使能、系统全局复位，这些信号都是低带宽的控制信号，FPGA 中有专用于实现低速率、低带宽信号传输的 AXI-GPIO^[67]，本文采用 AXI-GPIO 传输方式回传控制信号。上位机通过 TCP/IP 协议传回 ARM 端后，使用 3 个配置相同的 AXI-GPIO，每一个 AXI-GPIO 通过 ARM 端进行对应的控制信号的读写配置，GPIO 配置如图 4-15，位宽均设为控制信号长度 1。




图 4-15 AXI-GPIO 配置

4.5 逻辑资源占用情况

以上为全部 FPGA 设计部分，逻辑资源占用情况如图 4-16，逻辑资源占用是指在 FPGA 中实现特定设计功能所需的硬件资源使用情况，主要包括 LUT、DSP、触发器（Flip-Flop，FF）和块存储器（Block RAM，BRAM）等。资源占用情况直接反映了设计对 FPGA 硬件资源的利用程度，直接影响芯片的时序收敛性和功耗。在本设计中，资源占用的功能模块包括 FPGA 片上光信号采集、信号解调、特征提取、数据上传以及控制下发模块。

Resource	Utilization	Available	Utilization %
LUT	143077	171900	83.23
LUTRAM	3415	70400	4.85
FF	216382	343800	62.94
BRAM	334	500	66.80
DSP	218	900	24.22
IO	32	250	12.80
BUFG	3	32	9.38

图 4-16 逻辑资源占用情况

4.6 上位机识别显示设计

系统的上位机识别显示部分分为三个模块：TCP/IP 接收发送、声纹识别和显示控制模块。各模块均由 Labview^[68]软件实现，作为上位机软件的优势在于其独特

的功能特性。首先，在硬件协同方面，Labview 具有强大的兼容性，支持 ARM 端和上位机之间通信采用的 TCP/IP 协议，支持通过动态链接库(Dynamic Link Library, DLL) 接口集成第三方功能模块，并兼容基于 Python 实现的文本识别算法脚本调用，通过标准化函数封装与脚本解释器协同调度，使系统可对多硬件平台进行统一资源调度。其次，其交互式前面板支持拖拽式 UI 设计，能够构建本文声纹识别系统需要的时域波形图、时空能量图、参数控制控件的显示及人机交互界面，满足实验室调试与工业现场监控的双重需求。最后，其图形化编程范式通过数据流驱动的可视化交互模式，将算法逻辑转化为节点连线图，大幅降低了开发系统的编码复杂度。

总的来说，基于 Labview 构建的上位机识别显示系统在软硬件跨语言协同方面具有极大优势，兼容 ARM 端与上位机的 TCP/IP 协议栈交互，还支持 Python 脚本的基于 GMM-UBM 模型的识别算法调用。这种软硬件融合的方案能够提升复杂声纹识别系统的工程化实施效率。

4.6.1 TCP/IP 接收发送模块

TCP/IP 接收发送模块作为 ARM 和上位机通信的核心组件，用于实现 MFCC 数据流接收和控制指令发送功能。通过绑定 ARM 端的 IP 地址与端口号，接收模块(TCP Read) 实时按照预设的数据格式读取 TCP 流式数据；发送模块则将本地控制指令封装为协议帧并推送至 ARM 端，支持单次或循环发送模式。

4.6.2 声纹识别模块

识别模块分为：数据转换和声纹识别。其中，声纹识别部分使用一个 Python 节点(Python Node) 调用本地 Python 识别算法脚本。

在接收到特征参数参数后，将对参数存储累积，按照 1s 滑窗将每次累积的 3s 参数送入识别模块：首先将每次传输的一个通道一帧 MFCC 参数的定点数据转换为 12 点浮点数组，并存入一个二维数组，当数组接收 N_{sample} 个通道各一帧数据后，将数组保存在一个三维数组中。接着，当三维数组接收满 186 帧数据后，将数组按照通道段数由低至高，输入 Python 节点进行循环 N_{sample} 次声纹识别，识别过程将调用本地保存的三个目标事件的 GMM 模型和一个非目标事件的 UBM 模型，分别计算每个通道 186*12 的特征参数与每个模型的 LLR，按照多分类判定方法确定事件类型。最后，节点输出判定的各通道对应事件的标签，显示模块根据标签显示识别结果。

4.6.3 显示控制模块

为显示实时的事件识别结果、事件的位置和信号波形，搭建一个针对管道入侵事件监测的声纹识别系统的显示控制界面，如图 4-17。




图 4-17 上位机显示界面

显示框架中有实时显示图谱包括时域波形图、时空图。图中左侧的时域波形图为经过解调后的通道信号波形，在设置空间索引即通道段数后将实时显示对应通道的信号时频波形；右侧的时空图构建了一个三维的时空可视化分布，通过多维度映射呈现了光纤链路的动态变化，横轴为光纤链路的物理位置，用通道段数表示，纵轴为时间，垂直于平面的 Z 轴为光纤瑞利散射光强，其强度变化反映了外界扰动对光纤传输特性的调制效应。

上位机控制结构中设置的触发探测采集、使能 MFCC 数据输入 AXI 总线、系统复位的控制集中使用一个控件控制，当点击“STOP”控件时，系统开始采集、解调、识别信号，当识别结果为目标事件时系统将开始报警，事件信息将显示在左侧的表格中，信息包含报警时间、报警位置和事件类型。

4.7 本章小结

本章系统性地阐述了管道入侵事件声纹识别系统的实现结构与算法设计，涵盖硬件架构、算法优化、数据传输及上位机协同环节。FPGA 端负责光信号的采集、解调及 MFCC 特征提取。在上位机实现了 GMM-UBM 模型识别推理功能，结合三维时空可视化界面，形成软硬件融合的认识系统。

在关键模块设计中，特征提取算法通过多维度优化显著提升了效率与资源利用率。预处理模块采用双 FIFO 分帧结构及有限状态机控制的乒乓缓冲操作，实现了串行数据流的实时分帧与重叠处理；梅尔倒谱计算模块实现了 16 点 DCT 变换优化，利用蝶形算法、移位-加法替代乘法，大幅降低乘法器资源消耗，同时使用

七级流水结构将各计算结构分解为独立的逻辑阶段，使计算深度并行化，提高数据处理的效率。数据传输方面，系统基于 AXI4-Stream 协议实现 FPGA 至 ARM 的高速数据流传输，结合 AXI-FIFO 跨时钟域缓存与 AXI-DMA 内存映射技术，保障特征参数实时上传；控制指令则通过 AXI-GPIO 回传，实现低带宽信号的交互。

第五章 基于 DAS 的声纹特征提取实验和性能验证

基于 FPGA 的声纹特征提取部分是本系统的核心设计，本章将首先实验分析硬件加速声纹特征提取算法的计算性能，接着搭建输气管道入侵事件的声纹识别系统应用于实际现场，检验其实际识别的准确率和实时性。


5.1 特征提取实验与性能分析

由于 MFCC 特征提取算法本身具有多级处理流程，涉及时频变换、梅尔滤波、对数能量提取及离散余弦变换等多个串行处理环节，在各模块的设计与实现过程中，必须对计算时序进行精确控制，本文设计中使用了多个计数器控制时序，因此在分析中加入对模块中关键结构的时序控制效果验证。最后对比特征提取部分结构使用本文 16 点 DCT 结构和直接计算的资源占用情况。


实验分析将分为三部分：信号预处理模块中状态机控制的双 FIFO 分帧结构输出测试验证、评估特征提取部分提取 MFCC 系数的处理周期性和计算性能。其中，输出测试验证包括：输出的准确性和处理的周期性；特征提取的计算性能包括计算的单次输出 MFCC 系数的耗时和对 500 个通道各 3s 数据的特征提取的总耗时；根据 16 点 DCT 设计结构对比使用蝶形结构和移位乘法的资源占用。

5.1.1 预处理模块测试验证

预处理模块的结果验证中，使用 Matlab 分别绘制分帧后的理论波形，对比 FPGA 分帧的输出波形，其中，输出准确性检验采用第一帧波形，处理周期性检验选择对比第二帧波形。使用三类信号样本按照 500 个通道信号在实际系统中的信号采集和解调后的信号输出模式，串行输入模式输入预处理模块，每个通道各三帧信号。在 100MHz 系统时钟下，500 个通道信号分帧后的第一帧信号理论波形和模块输出波形如图 5-1。




(a)




(b)

图 5-1 通道信号分帧第一帧理论波形及实验结果。(a) 信号理论波形；(b) 预处理波形

理论波形与 FPGA 输出波形的形状、幅度基本相符，表明分帧模块在处理第一帧信号时具有较高的准确性。500 个通道信号分帧后的第二帧信号理论波形和预处理模块分帧输出波形如图 5-2，第二帧的理论波形与 FPGA 输出波形仍基本相符且数据量相同，没有出现数据丢失或冗余，因此验证模块中的状态机控制的双 FIFO 结构实现的每个分帧过程均具备完整周期。



(a)



(b)

图 5-2 各通道分帧信号第二帧理论波形及实验结果。(a) 信号理论波形；
(b) 预处理输出波形

5.1.2 特征提取部分处理周期性和计算性能评估

在特征提取部分提取 MFCC 系数的处理周期性和计算性能评估中, 输入部分采用与预处理模块性能验证实验中相同的输入信号, 时钟为 100MHz。

针对算法处理的周期性验证, 通过特征提取一帧信号的耗时计算理论提取 500 通道的各一帧信号的耗时, 检验理论值和实验时间结果。实验耗时如图 5-3, 图(b)展示了从一帧参数计算完成到下一参数输出的等待时间为 310 ns, 即计算下一通道的一帧 MFCC 的时间。一帧信号的 MFCC 的输出持续时间为一个时钟周期 10ns, 此时可以计算 500 通道各一帧特征提取的总时长应该为 159.69 μ s, 与图(c)显示的从输出第一个参数至输出第 500 个参数的总耗时 159.69 μ s 相符, 至此可以验证算法处理具有周期性, 一个周期为 310ns。




图 5-3 梅尔倒谱系数计算耗时。(a) 第一个参数; (b) 相邻参数间; (c) 500 个通道; (d) 相邻的 500 个通道间

在计算性能评估部分, 通过从预处理到输出第一帧 MFCC 系数的初始化时间, 再到输出 500 个通道的第一帧 MFCC 系数耗时以及相邻 500 个通道计算完成的时

间间隔, 计算特征提取部分对 500 个通道各 3s 信号特征提取的总耗时。计算公式如式 5-1:

$$t_{mfcc} = t_{init} + n_{frame} t_{first} + (n_{frame} - 1) t_{interval} \quad (5-1)$$

其中, n_{frame} 为识别信号的帧数。图 5-3 (d) 为从完成 500 个通道各一帧数据计算到完成下一帧数据计算的时间间隔, 间隔时间为 1400.31 μs ; 图 5-3 (a) 中第一个系数的计算耗时包含从信号输入到完成计算第一个通道第一帧信号的 MFCC 系数的耗时, 约为 3.19ms, 其中主要耗时部分分布在预处理模块的数据累积模块中, 写入第一个 8000 深度的初始化时间, 图 5-1 (b) 中标注了等待时间, 约为 3185.16 μs 。在预处理模块中, 对 3 秒数据进行分帧处理共分为 186 帧, 根据图 5-7 的时域信号波形分析可知, 3 秒的采样时长可完整覆盖三类信号中每个类别至少一个周期波形。通过式 5-1 能够计算 500 个通道各 3s 数据的特征提取总耗时约为 399.35ms, 耗时远小于信号的时长, 符合系统对于 500 个通道各 3s 数据特征提取部分耗时小于 3s 的需求, 对于管道沿线 5km 及其以内的距离均可实现实时监测。

同时, 可以计算监测最长距离, 最长距离是在各通道响应时间 3s 以内的条件下, 系统能够监测的光缆沿线最长距离, 由 FPGA 的 RAM、FIFO IP 的最大深度和各模块的计算等待时间、计算一帧 MFCC 参数时间共同决定, 在输入信号位宽 32bit 的情况下, 由 5-1 公式计算可监测的最多通道数为 9364, 特征提取部分分帧结构的 FIFO 最大深度为 131027, 计算的最大通道数为 8189, RAM 最大深度为 564000, 最大通道数为 17625, 所以取三者最小值, 在保证实时性的前提下, 系统可监测的最多通道数为 8189。

5.1.3 资源占用对比

使用本文改进的输入加法器-中间乘法器-输出加法器协同优化单元的 DCT 计算结构可以降低乘法资源的消耗, 对比使用 HEVC 标准的系数矩阵直接展开 DCT 公式的计算方法, 两种方法进行综合前仿真的资源占用情况如图 5-4, 两种方法使用的 LUTRAM 和 DSP 资源相同, 差别在于 LUT 和 FF 的使用情况, 相较于图 (b) 直接展开计算方案, 图 (a) 中本文设计的 DCT 计算结构的 FF 使用减少了 2.24%, LUT 减少了 5.81%。这是由于乘法计算过程中倒谱系数和矩阵系数的位宽分别为 41 和 8, 乘法器是否映射到 DSP48 模块取决于输入位宽和工具优化策略, 若位宽超过 DSP48 支持范围或无法对齐其流水线结构^[69], 综合器将自动选择 LUT 实现, 这样极大增加了 LUT 的使用率。

Resource	Estimation	Available	Utilization %
LUT	61161	171900	35.58
LUTRAM	163	70400	0.23
FF	148683	343800	43.25
DSP	22	900	2.44
IO	409	250	163.60
BUFG	1	32	3.13

(a)

Resource	Estimation	Available	Utilization %
LUT	71148	171900	41.39
LUTRAM	163	70400	0.23
FF	140981	343800	41.01
DSP	22	900	2.44
IO	409	250	163.60
BUFG	1	32	3.13

(b)

图 5-4 特征提取部分资源占用情况。(a) 使用本文 DCT 计算结构；(b) 使用 DCT 公式展开计算

5.2 系统搭建

在验证了特征提取部分各结构的性能与理论相符，且能够应用于识别系统后，本节将搭建针对长距离输油气管道入侵事件的声纹识别系统，并对该系统的综合性能进行实际现场的验证评估。该系统主要由以下模块构成：

1. DAS 光学集成模块：DAS 光学集成模块如图 5-5，模块采用集成化设计，主要包含光电器件有窄线宽激光器、声光调制器、平衡光电探测器等，各结构的具体功能已在第二章中介绍。DAS 光学集成模块通过光纤连接器（FC/APC）与光纤链路连接，根据实际应用场景的空间布局配置相应长度光纤。



图 5-5 DAS 光学集成模块照片

2. 采集-处理板卡：信号采集部分选择 AD9643 作为信号采集芯片，信号处理部分的板卡采用 Xilinx@-XC7Z035FFG676-2 作为主控芯片。板卡如图 5-6。




图 5-6 采集-处理板卡结构

AD9643 的结构参数、采集时序已在第二章中介绍。ZYNQ-7035 集成双核 ARM Cortex-A9 MPCore 处理器，具备强大的处理能力和多任务处理能力，FPGA 架构为 Kintex-7，逻辑资源包括 900 个 DSPs、500 个 BRAM、171900 个查找表（Look-Up Tables, LUTs），芯片资源都满足系统的设计需求，和信号采集芯片构成采集处理传输一体化板卡，实现高速数据传输和信号处理。

3. 上位机：用于运行识别程序和显示部分界面。

基于以上模块搭建的输气管道入侵事件的声纹识别系统如图 5-7 输气管道入侵事件的声纹识别系统示意图




图 5-7 输气管道入侵事件的声纹识别系统示意图

5.3 测试性能

测试性能为响应时间和识别准确率。响应时间计算从入侵事件发生到系统完成识别并触发报警的时间延迟，系统每次识别到目标事件时都将显示报警信息；识别准确率统计系统对各类事件报警的结果，根据正确的报警次数占比计算准确率。

5.4 现场测试


将识别系统应用在输气管道现场，接入通信光缆，通过在光缆附近模拟人工挖掘、油夯机施工和挖机挖掘，测试其对管道中三类事件的识别能力和实时性。


该测试在输气管道沿线，一个开阔且较安静的试验区域进行，光缆埋设在地面下。测试现场如图 5-8，挖掘均发生在光缆传输路径附近。



图 5-8 输气管道现场测试图。(a) 挖机挖掘；(b) 人工挖掘；(c) 油夯机施工

当存在挖掘及施工情况时，上位机显示界面的时空图中会产生明显的强度响应，人工、挖机、油夯机施工时系统的响应界面如图 5-9：





(c)

图 5-9 系统实时响应界面。(a) 人工挖掘；(b) 挖机挖掘；(c) 油夯机施工

三类事件均发生在 113 段，由于这一段的振动传递到了相邻段，导致 109-115 段的时空图中有明显的能量变化。图 (a) 中的人工挖掘事件通过时域图能看到明显的事件特征，系统的识别响应较规律；图 (b) 挖机挖掘信号能量较人工挖掘信号更强，和实验的波形分布类似，信号的规律性较弱。由于挖机相邻两次挖掘时间间隔较长，期间会存在识别为非目标事件的情况；图 (c) 的油夯机施工信号能量最强，报警响应更频繁。

结合三类信号的实际报警时间能够粗略估计响应时间，从采集到识别，相邻两次报警的识别时间为 1-2s，除去等待输入是 1s 时间间隔，因此系统对挖掘事件的平均识别时间约 0.5s，符合系统对识别时间小于 3s 的实时性需求。

根据第 113 段发生的三类事件和随机一段的非目标事件，统计系统的报警结果计算系统的识别准确率，各事件统计 120s，即识别 118 次识别正确的次数，计算识别准确率。报警结果如表 5-1：

表 5-1 识别报警结果

信号类型	正确报警次数	识别准确率
人工挖掘	104	0.8813
挖机作业	109	0.9237
油夯机挖掘	106	0.8983
非目标事件	112	0.9491

由表中数据计算系统的平均识别准确率为 0.9131，同时，系统对于三类事件的实时识别准确率均达到 88% 以上。

最后，结合 5.1.2 最长监测通道数结论，给出系统监测性能指标，如表 5-2，性能包含系统响应时间、监测最长距离和平均识别准确率。

表 5-2 识别系统性能指标

性能	指标
响应时间	0.5s
监测最长距离	81.89km
平均识别准确率	0.9131

5.5 本章小结

本章围绕基于 FPGA 的声纹特征提取算法及输气管道入侵识别系统的设计与实现展开系统性研究。

通过实验验证了 MFCC 特征提取算法的硬件实现性能：预处理模块采用状态机控制的双 FIFO 分帧结构，实验结果表明分帧输出的理论波形与 FPGA 波形在形状、幅度及数据量上均高度相同，且未出现数据丢失或冗余，证明了分帧过程的周期性和准确性；在特征提取模块中，500 个通道 3 秒数据的总处理耗时 399.35ms，验证了系统对 500 通道各 3 秒数据的特征提取总耗时远低于 3 秒，满足实时性需求。在此基础上搭建的声纹识别系统由 DAS 光学集成模块、ZYNQ-7035 主控板卡及上位机构成，现场测试中，系统接入光缆链路，对人工挖掘、挖机挖掘及油夯机施工三类事件进行实时监测，结果显示三类事件的平均响应时间均低于 3 秒。

综合实验与实测结果，系统在特征提取效率、识别实时性及多事件分类能力上均达到设计要求，为输气管道安全监测提供了可靠的工程化解决方案，验证了硬件加速声纹识别技术的实际应用价值。

第六章 总结与展望

本文针对光纤分布式声波传感系统在管道入侵监测中的实际需求，提出了一种基于 FPGA 加速的多通道声纹识别算法与硬件架构设计，实现了从数据采集、特征提取到事件识别的全流程实时性优化，通过融合声纹识别技术与 FPGA 的并行计算能力，解决传统多维特征融合和深度学习方法计算复杂度高、实时性不足的瓶颈问题。本文的创新之处主要体现在：尝试将声纹识别技术引入 DAS 系统，以声学特征替代传统多维参数融合，在保证较高识别率的同时，降低了算法复杂度；根据 DAS 系统信号的多通道并发传输特性，提出了基于 FPGA 的多通道信号 MFCC 计算结构，通过蝶形运算、乒乓缓冲等设计实现硬件加速与资源高效利用；构建采集-特征提取-传输-识别显示一体化管道入侵事件声纹识别系统，支持多通道并行处理与时空可视化，为工业物联网场景提供了轻量化、低延迟的解决方案。

本文研究内容如下：

以工业物联网背景下 DAS 系统在管道入侵监测中的实时性与计算复杂度问题为切入点，系统分析了传统多维特征参数融合技术与深度学习方法在数据处理效率、资源消耗及响应延迟等方面的局限性，提出将声纹识别技术应用于入侵监测的解决方案，梳理了声纹识别技术从倒谱分析、MFCC 特征到深度学习模型的发展脉络。

针对管道入侵事件的油夯机施工、挖机挖掘及人工挖掘三类信号提出基于声纹识别的分类算法。通过对比分析 LPC、LPCC 和 MFCC 的特征提取方法，结合信号时频特性选定 MFCC 作为特征参数；理论分析 GMM-UBM 模型的实时性优势，确定采用 GMM-UBM 为识别模型，通过 EM 算法训练参数、MAP 自适应调整目标事件模型，并设计多阈值判决机制以降低单阈值导致的拒绝率问题。实验表明，针对三类管道入侵事件识别，高斯模型数量为 12、梅尔滤波器数量为 16 且不引入动态参数时，系统总等错误率最低为 0.1991，验证集平均识别率达 97.51%，当通道段数为 500 时，模型的识别时间仅 8.31ms。研究验证了该算法在分类精度、实时性及资源效率上的优势，满足管道入侵监测的工程需求。

在硬件层面，研究了基于 FPGA 的分布式光纤管道入侵事件监测系统结构和系统的探测、采集、解调原理。搭建了光学集成模块、FPGA 与 ARM 协同的管道入侵事件声纹识别系统。优化了基于 FPGA 的 MFCC 特征提取流程，采用双 FIFO 分帧结构、蝶形算法及七级流水线设计，以移位-加法替代浮点乘法，降低了资源消耗；结合 AXI4-Stream 协议与 AXI-DMA 实现多通道数据高速传输；上位机基于

Labview 构建交互界面，调用 GMM-UBM 模型进行多阈值分类识别，并通过三维时空可视化界面实时显示事件位置及波形。通过实验与现场测试验证了基于 FPGA 的声纹特征提取算法及管道入侵识别系统的性能，实验表明，预处理模块采用双 FIFO 分帧结构，理论波形与 FPGA 输出波形在形状、幅度及数据量上相符，实现了准确分帧；特征提取模块处理 500 通道各 3s 数据的总耗时仅 399.35ms，满足系统的实时性需求。现场测试中接入输气管道的光缆，模拟人工挖掘、挖机挖掘及油夯机施工三类入侵事件，系统平均识别准确率为 91.31%，响应时间低于 0.5s，系统在多通道实时处理、事件分类精度及资源效率方面均达到设计要求，为管道安全监测提供了可靠的解决方案。

本文存在的不足和改进方向如下：

特征提取部分的预处理模块需要开辟足够的 RAM 和 FIFO 深度进行多通道的数据累积分帧，本文监测是基于 1kHz 重频下进行的，所以每帧的长度较短，在 32bit 量化精度下，RAM 的最大深度为 564000，FIFO 的最大深度为 131072，然而在对重频有更高要求的监测环境中，帧长度也会成比例增加，此时需要调整资源占用压缩有效监测通道数或数据位宽，系统的长距离监测性能有所降低。解决该问题可采用动态帧长调整技术，在监测到高频分量时控制有效帧长，维持更高的通道监测容量，更进一步，可引入压缩技术，利用声纹信号的帧间相关性，在存储前进行无损压缩。

系统设计选择声纹识别模型时并未计划将模型硬件加速，考虑到识别的实时性，选择了 GMM-UBM 轻量化的声纹识别模型，模型对稳态背景噪声和加入 UBM 训练的非目标事件具有较强抗干扰能力，在特定的场景下能够达到较高识别率，但传统统计模型存在显著局限性，其建模过程高度依赖训练数据的分布特性，当实际应用场景中出现事件动态变化，如挖掘频率陡增，或在不同场景下监测时，缺乏特征自适应能力。相比之下，神经网络模型则具有更高的鲁棒性，在干扰的鲁棒性、跨场景泛化能力方面表现更优，在实时性方面，神经网络的部署需配套专用加速芯片，这对边缘计算设备的算力架构提出了更高要求。

参考文献

- [1] Tracey P M. Intrinsic fiber-optic sensors[J]. IEEE Transactions on Industry Applications, 1991, 27(1): 96-98.
- [2] 夏磊, 闫巍. 我国安防行业发展现状与态势分析[J]. 电信网技术, 2018(3): 21-24.
- [3] 侯俊芳, 裴丽, 李卓轩, 等. 光纤传感技术的研究进展及应用[J]. 光电技术应用, 2012, 27(1): 49-53.
- [4] Juarez J C, Maier E W, Choi K N, et al. Distributed fiber-optic intrusion sensor system[J]. Journal of Lightwave Technology, 2005, 23(6): 2081-2087.
- [5] Martins H F, Piote D, Tejedor J, et al. Early detection of pipeline integrity threats using a smart fiber-optic surveillance system: the pit-stop project[C]. 24th International Conference on Optical Fibre Sensors, Curitiba, Brazil, 2015: 96347X-1-96347X-4.
- [6] WU H, Liu X, Xiao Y, et al. A dynamic time sequence recognition and knowledge mining method based on the hidden markov models(HMMs) for pipeline safety monitoring with Φ -OTDR[J]. Journal of Lightwave Technology: A Joint IEEE/OSA Publication, 2019, 37(19): 4991-5000.
- [7] Qin Z, Chen L, Bao X. Wavelet denoising method for improving detection performance of distributed vibration sensor[J]. IEEE Photonics Technology Letters, 2012, 24(7): 542-544.
- [8] Tang S, Chen L, He K, et al. Computational intelligence and deep learning for next-generation edge-enabled industrial IoT[J]. IEEE Transactions on Network Science and Engineering, 2023, 10(5): 2881-2893.
- [9] Li X, Wu Y, Liu C, et al. Voiceprint recognition-based power transformer fault detection for enhancing safety maintenance of electrical systems[C]. 2024 IEEE International Conference on Energy Internet, Zhuhai, China, 2024: 355-360.
- [10] Kersta L G. Voiceprint identification[J]. Nature, 1962, 196(4861): 1253-1257.
- [11] Rabiner L R, Schafer R W, Schafer R W. Introduction to digital speech processing[J]. Foundations and Trends in Signal Processing, 2007, 1(1): 1-194.
- [12] Atal B S. Automatic recognition of speakers from their voices[J]. Proceedings of the IEEE, 1976, 64(4): 460-475.
- [13] Sakoe H, Chiba S. Dynamic programming algorithm optimization for spoken word recognition[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1978, 26(1): 43-49.

- [14] Davis S, Mermelstein P. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1980, 28(4): 357-366.
- [15] Doddington G R. Speaker recognition—Identifying people by their voices[J]. Proceedings of the IEEE, 1985, 73(11): 1651-1664.
- [16] Azam M, Bouguila N. Speaker verification using adapted bounded gaussian mixture model[C]. 2018 IEEE International Conference on Information Reuse and Integration, Salt Lake City, UT, USA, 2018: 300-307.
- [17] Che C, Lin Q, Yuk D. An HMM approach to text-prompted speaker verification[C]. 1996 IEEE International Conference on Acoustics, Speech, and Signal Processing, Atlanta, GA, USA , 1996: 673-676.
- [18] Campbell W M, Campbell J P, Reynolds D A, et al. Support vector machines for speaker and language recognition[J]. Computer Speech & Language, 2006, 20(2): 210-229.
- [19] Dehak N, Dumouchel P, Kenny P. Modeling prosodic features with joint factor analysis for speaker verification[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2007, 15(7): 2095-2103.
- [20] Hossan M A, Memon S, Gregory M A. A novel approach for MFCC feature extraction[C]. 2010 4th International Conference on Signal Processing and Communication Systems, Gold Coast, QLD, Australia, 2010: 1-5.
- [21] Variani E, Lei X, McDermott E, et al. Deep neural networks for small footprint text-dependent speaker verification[C]. 2014 IEEE International Conference on Acoustics, Speech and Signal Processing, Florence, Italy, 2014: 4052-4056.
- [22] Li C, Ma X, Jiang B, et al. Deep speaker: an end-to-end neural speaker embedding system[DB/OL]. 2017, <https://arxiv.org/abs/1705.02304>.
- [23] Snyder D, Garcia-Romero D, Sell G, et al. X-Vectors: robust DNN embeddings for speaker recognition[C]. 2018 IEEE International Conference on Acoustics, Speech and Signal Processing, Calgary, AB, Canada, 2018: 5329-5333.
- [24] 陈佳音. 基于光纤 MOEMS 声传感器技术的声纹识别系统研究[D]. 吉林: 长春理工大学, 2016.
- [25] 王丰华, 王邵菁, 陈颂, 等. 基于改进 MFCC 和 VQ 的变压器声纹识别模型[J]. 中国电机工程学报, 2017, 37(5): 1535-1542.
- [26] 杨佳沛, 王宇, 彭广建, 等. 基于 DTW-GMM 的光纤传感系统声纹识别方法[J]. 电子测量与仪器学报, 2024, 38(4): 176-186.

- [27] 沈隆翔. 基于下变频和 IQ 解调的外差 Φ -OTDR 模式识别方法[D]. 天津: 天津大学, 2017.
- [28] 盛智勇, 屈丹丹, 张远, 等. 光纤入侵信号检测及识别算法的嵌入式实现[J]. 光电子. 激光, 2018, 29(3): 287-297.
- [29] 翁凌锋. 基于迈克尔逊干涉仪的光纤周界安防系统入侵事件识别算法研究[D]. 天津: 天津大学, 2019.
- [30] 闫建行, 玄兆燕, 谢世满, 等. 长距离光纤油气管道预警监测系统设计[J]. 光通信技术, 2020, 44(1): 23-26.
- [31] 杨家隆. 基于 FPGA 的 EFPI 光纤传感器的干涉信号处理[D]. 辽宁: 大连理工大学, 2020.
- [32] 赵攀峰, 王一群. 基于 FPGA 与卷积神经网络的零件识别系统[J]. 仪表技术与传感器, 2023, (4): 72-76, 82.
- [33] 刘佳. 基于偏振检测的分布式光纤振动传感研究[D]. 天津: 天津大学, 2012.
- [34] Kuppuswamy H. An experimental investigation of the sensitivity of a buried fiber optic intrusion sensor[D]. Texas: Teaxs A&M University, 2005.
- [35] 张旭苹. 全分布式光纤传感技术[M]. 北京: 科学出版社, 2013: 62.
- [36] Taylor H F, Lee C E. Apparatus and method for fiber optic intrusion sensing: US19910737449[P]. 1993-03-16.
- [37] Murray M J, Redding B. Distributed multimode fiber Phi-OTDR sensor using a high-speed camera[J]. OSA Continuum, 2021, 4(2): 579.
- [38] 沈隆翔, 封皓, 沙洲, 等. 基于下变频和 IQ 解调的外差型相位敏感光时域反射技术的模式识别[J]. 光学学报, 2017, 37(8): 88-97.
- [39] Tu X, Sun Q, Chen W, et al. Vector brillouin optical time-domain analysis with heterodyne detection and IQ demodulation algorithm[J]. IEEE Photonics Journal, 2014, 6(2): 1-8.
- [40] Chen D, Liu Q, He Z. Phase-detection distributed fiber-optic vibration sensor without fading-noise based on time-gated digital OFDR [J]. Optics Express, 2017, 25(7): 8315-8325.
- [41] Gabai H, Eyal A. On the sensitivity of distributed acoustic sensing[J]. Optics Letters, 2016, 41(24): 5648-5651.
- [42] Cui K, Liu F, Wang K, et al. Interference-fading-suppressed pulse-coding Φ -OTDR using spectrum extraction and rotated-vector-sum method[J]. IEEE Photonics Journal, 2021, 13(6): 1-6.
- [43] 邓超, 刘明亮. 基于"NTN"校准法的相位解卷绕技术[J]. 中国计量学院学报, 2003, 14(4): 251-254, 303.
- [44] 陈典. 基于时间门控数字光频域反射仪的高性能光纤分布式声波传感系统研究[D]. 上海: 上海交通大学, 2020.

- [45] 周毅炜. 光纤分布式传感系统在胶带机故障信号检测中的应用研究[D]. 成都: 电子科技大学, 2023.
- [46] Macková L, Čiřmár A, Juhár J. Best feature selection for emotional speaker verification in ivector representation[C]. 2015 25th International Conference Radioelektronika, Pardubice, Czech Republic, 2015: 209-212.
- [47] 徐卫中. 基于矢量量化与神经网络的声纹识别系统的研究[D]. 重庆: 重庆大学, 2012.
- [48] Lee M, WANG H. An extended Levinson-Durbin algorithm for the analysis of noisy autoregressive process[J]. IEEE Signal Processing Letters, 1996, 3(1): 13-15.
- [49] 王正创. 基于 MFCC 与共振峰的声纹识别算法研究[J]. 电脑知识与技术, 2016, 12(4): 188-190.
- [50] 鲁晓倩, 关胜晓. 基于 VQ 和 GMM 的实时声纹识别研究[J]. 计算机系统应用, 2014, (9): 6-12.
- [51] Xiong Z, Zheng T F, Song Z, et al. Combining selection tree with observation reordering pruning for efficient speaker identification using GMM-UBM[C]. 2005 IEEE International Conference on Acoustics, Speech, and Signal Processing, Philadelphia, USA, 2005: 625-628.
- [52] 李伟, 曾繁洋, 王博, 等. 基于 MFCC 加权动态特征组合的声纹识别技术在地下电缆防护的应用[J]. 电力信息与通信技术, 2022, 20(5): 16-22.
- [53] 周玥媛, 孔钦. 基于 GMM-UBM 的声纹识别技术的特征参数研究[J]. 计算机技术与发展, 2020, 30(5): 76-83.
- [54] Reynolds D A, Rose R C. Robust text-independent speaker identification using Gaussianmixture speaker models[J]. IEEE Transactions on Speech and Audio Proceeding: A Publication of the IEEE Signal Processing Society, 1995, 3(1): 72-83.
- [55] 朱周华. 期望最大(EM)算法及其在混合高斯模型中的应用[J]. 现代电子技术, 2003, 26(24): 88-90.
- [56] Cheng Y. Mean shift, mode seeking, and clustering[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1995, 17(8): 790-799.
- [57] 朱军, 胡文波. 贝叶斯机器学习前沿进展综述[J]. 计算机研究与发展, 2015, 52(1): 16-26.
- [58] Reynolds D A. Comparison of background normalization methods for text-independent speaker verification[C]. 5th European Conference on Speech Communication and Technology, Rhodes, Greece, 1997: 963-966.
- [59] Anithadevi N, Gokul P, Nandan S M, et al. Automated speech recognition system for speaker emotion classification[C]. 5th International Conference on Computing, Communication and Security, Patna, India, 2020: 1-5.

- [60] 王成, 刘亚峰, 王新成, 等. 分类器的分类性能评价指标[J]. 电子设计工程, 2011, 19(8): 13-15, 21.
- [61] Sullivan G J, OHM J -R, HAN W -J, et al. Overview of the high efficiency video coding (HEVC) standard[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2012, 22(12): 1649-1668.
- [62] 钟文荣, 陈建发. 二维 DCT 算法的高速芯片设计[J]. 厦门大学学报(自然科学版), 2005, 44(2): 198-201.
- [63] ARM. AMBA AXI Protocol Specification[EB/OL]. 2023, <https://developer.arm.com/documentation>.
- [64] 马飞, 刘琦, 包斌. 基于 FPGA 的 AXI4 总线时序设计与实现[J]. 电子技术应用, 2015, 41(6): 13-15, 19.
- [65] Xilinx. LogiCORE IP AXI4-Stream FIFO[EB/OL]. 2012, https://docs.xilinx.com/v/u/enUS/ds806_axi_fifo_mm_s.
- [66] 蒲杰, 李贵勇. 基于 AXI 总线的 DMA 控制器的设计与实现[J]. 重庆邮电大学学报(自然科学版), 2012, 24(2): 174-177.
- [67] Kumar A, Rajpal R, Pujara H, et al. Universal interface on Zynq (R) SoC with CAN, RS-232, Ethernet and AXI GPIO for instrumentation & control[J]. Fusion Engineering and Design, 2016, 112: 865-871.
- [68] 解璞, 李瑞. LabVIEW 2014 基础实例教程: 附微课视频[M]. 978-7-115-43593-4, 北京: 人民邮电出版社, 2017.
- [69] Paz P, Garrido M. Efficient implementation of complex multipliers on FPGAs using DSP slices[J]. Journal of Signal Processing Systems, 2023, 95(4): 543-550.